Entraînement des réseaux de neurones : difficultés et choix pratiques

CSI 4506 - automne 2026

Marcel Turcotte
Version : 1 nov. 2026 17h45

Préambule

Message du jour

https://youtu.be/0Ge3jKLDJaA

The collie and the pug | HackMIT keynote 2026, publié sur YouTube le 24 septembre 2026.

> **Note**
>
> Grant Sanderson examine l'évolution du rapport entre la compréhension technique et la création de logiciels. En comparant les motivations de différentes approches, cette conférence invite les participants à réfléchir à leurs propres objectifs d'apprentissage et de création pendant l'événement.

Grant Sanderson est le créateur de 3Blue1Brown, une chaîne YouTube reconnue pour ses explications visuelles particulièrement claires des mathématiques. Son travail a contribué à populariser une approche intuitive de l'enseignement des mathématiques en ligne, fondée sur l'animation.

Objectifs d'apprentissage

- **Expliquer** comment les paysages de perte, les dérivées des activations et l'initialisation influencent l'optimisation.
- **Distinguer** les gradients évanescents, les gradients explosifs et le surapprentissage.
- **Choisir** les activations de sortie et les pertes pour la régression et les classifications binaire, multiétiquette et multiclasse.
- **Expliquer** L1, L2, le dropout et l'arrêt précoce, et interpréter leurs effets dans le code.

- **Comparer** `SimplerMLP` à `SimpleMLP` et distinguer l'inférence de la poursuite de l'apprentissage.
- **Reconnaître** l'oubli catastrophique et expliquer comment le rejeu d'anciens exemples peut améliorer la rétention.

La présentation 13 a calculé les gradients par rétropropagation. Cette présentation examine les difficultés qui subsistent : l'optimisation peut stagner ou devenir instable, un modèle peut surapprendre et la poursuite de l'entraînement peut dégrader des capacités antérieures. Les sorties et les pertes définissent le problème de prédiction; l'initialisation, les règles de mise à jour et la régularisation influencent sa résolution.

Paysages de perte et optimisation

Nous avons les gradients. Quelles difficultés subsistent?

La rétropropagation a été popularisée en **1986**. Pourquoi l'apprentissage profond a-t-il pris son essor beaucoup plus tard?

- Le **paysage de perte** décrit la fonction objectif en fonction des paramètres.
- Un gradient décrit la variation **locale** de cette fonction.
- Les progrès dépendent aussi des paramètres initiaux et du taux d'apprentissage.

L'article influent de Rumelhart, Hinton et Williams, publié en 1986, a contribué à populariser la rétropropagation pour entraîner des réseaux de neurones multicouches (Rumelhart et al. 1986). Comme le précise la présentation 13, des travaux sur cette méthode et sur la différentiation automatique en mode inverse lui sont antérieurs. Cette année marque une démonstration et une diffusion influentes, plutôt que le début de tous les travaux pertinents.

Des succès pratiques ont précédé l'essor récent de l'apprentissage profond. Dans les années 1990, des réseaux entraînés par rétropropagation servaient à reconnaître l'écriture manuscrite et les chèques. L'adoption plus large de grands réseaux profonds est venue plus tard; les progrès en reconnaissance de la parole vers 2009 et la compétition ImageNet de classification d'images de 2012 ont constitué des étapes marquantes (LeCun et al. 2015). Cette progression sur plusieurs décennies concerne donc l'ampleur et la diversité des succès; elle ne signifie pas que tous les réseaux antérieurs étaient inefficaces.

Des jeux de données étiquetées plus volumineux et des calculs plus rapides, notamment grâce aux processeurs graphiques (GPU), se sont combinés à des **architectures adaptées** et à de **meilleurs choix d'entraînement**. Le résultat d'AlexNet sur ImageNet en 2012 associait l'entraînement sur GPU, des **activations ReLU**, du **dropout** et des

exemples supplémentaires obtenus en transformant des images existantes (Krizhevsky et al. 2012). La rétropropagation fournissait les gradients dans cet ensemble de choix pratiques. Les activations, l'initialisation, l'optimisation et la régularisation abordées ici expliquent pourquoi calculer les gradients ne suffit pas à assurer un apprentissage efficace.

La rétropropagation indique comment la perte actuelle varie lorsque les paramètres changent. Un apprentissage utile exige aussi une fonction objectif appropriée, des mises à jour efficaces, une généralisation à de nouveaux exemples et la préservation des acquis lorsque l'apprentissage se poursuit. Une première difficulté apparaît déjà avec un seul paramètre : une direction localement correcte ne mène pas nécessairement à la meilleure solution globale.

Un même algorithme de descente de gradient peut se comporter différemment selon la fonction objectif. Un graphique unidimensionnel permet d'examiner entièrement un paysage simplifié (*loss landscape*). Un réseau réel possède généralement de nombreux paramètres : une vallée ou un plateau dessiné illustre une difficulté possible, sans représenter l'ensemble de sa fonction objectif. Un point stationnaire n'est pas nécessairement un minimum global. En grande dimension, des points de selle peuvent aussi apparaître : la perte augmente dans certaines directions et diminue dans d'autres. Un graphique unidimensionnel ne montre pas toute cette géométrie.

Un **minimum local** est au moins aussi bon que les valeurs voisines des paramètres; un **minimum global** est au moins aussi bon que toutes les valeurs admissibles. Un **point stationnaire** possède un gradient nul, là où la fonction objectif est différentiable. Il peut s'agir d'un minimum, d'un maximum ou d'un point de selle. La **convergence** désigne l'approche de valeurs limites des paramètres ou de la fonction objectif au cours d'une procédure itérative; elle ne garantit pas l'optimalité globale. La présentation 4 a introduit la distinction entre minimum local et global ainsi que la convexité.

La présentation 11 distinguait l'existence de paramètres utiles de la possibilité de les trouver. La rétropropagation permet de calculer efficacement les gradients; elle ne supprime pas cette distinction.

Où la descente de gradient nous mènera-t-elle?

Partons de chaque point vert. Avec un petit taux d'apprentissage constant, où les mises à jour pourraient-elles s'arrêter?

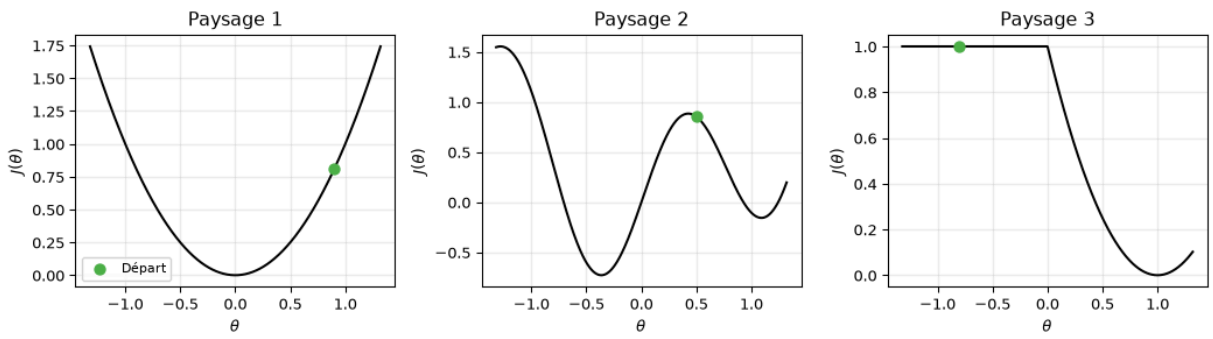
In [2]:
```
import numpy as np
import matplotlib.pyplot as plt

def gradient_descent_1d(gradient, start, learning_rate, steps, clip_value=Nc
    trajectory = [float(start)]
    for _ in range(steps):
```

```
        g = float(gradient(trajectory[-1]))
        if not np.isfinite(g):
            break  # La fonction simplifiée n'a pas de dérivée finie ici.
        if clip_value is not None:
            g = np.clip(g, -clip_value, clip_value)
        trajectory.append(trajectory[-1] - learning_rate * g)
    return np.asarray(trajectory)

def plot_landscape(objective, trajectory, ax, title, show_trajectory=True):
    left = min(-1.2, trajectory.min())
    right = max(1.2, trajectory.max())
    padding = 0.05 * (right - left)
    theta = np.linspace(left - padding, right + padding, 800)
    ax.plot(theta, objective(theta), color='black', linewidth=1.5)
    if show_trajectory:
        ax.plot(trajectory, objective(trajectory), 'o-', color='#377eb8',
                markersize=3, linewidth=0.8, alpha=0.65)
    ax.scatter(trajectory[0], objective(trajectory[0]), color='#4daf4a',
               s=45, zorder=4, label='Départ')
    if show_trajectory:
        ax.scatter(trajectory[-1], objective(trajectory[-1]), color='#d95f02
                   s=45, zorder=5, label='Fin')
    ax.set(title=title, xlabel=r'$\theta$', ylabel=r'$J(\theta)$')
    ax.grid(alpha=0.25)
    return theta


fig, axes = plt.subplots(1, 3, figsize=(11, 3.2))
overview = [
    ('Référence convexe', lambda t: t**2, lambda t: 2*t, 0.9, 0.1),
    ('Minima locaux', lambda t: 0.8*np.sin(4*t)+0.5*t**2,
     lambda t: 3.2*np.cos(4*t)+t, 0.5, 0.05),
    ('Région plate sous-optimale', lambda t: (np.maximum(0, t)-1)**2,
     lambda t: 2*(t-1) if t > 0 else 0.0, -0.8, 0.1)
]
for index, (ax, (_, objective, gradient, start, rate)) in enumerate(zip(axes
    trajectory = gradient_descent_1d(gradient, start, rate, steps=60)
    plot_landscape(objective, trajectory, ax, f'Paysage {index+1}',
                   show_trajectory=False)
axes[0].legend(fontsize=8)
fig.tight_layout()
plt.show()
```



Chaque graphique présente une fonction objectif et une valeur initiale du paramètre, avant de révéler les mises à jour. Le gradient décrit la pente au point courant; il

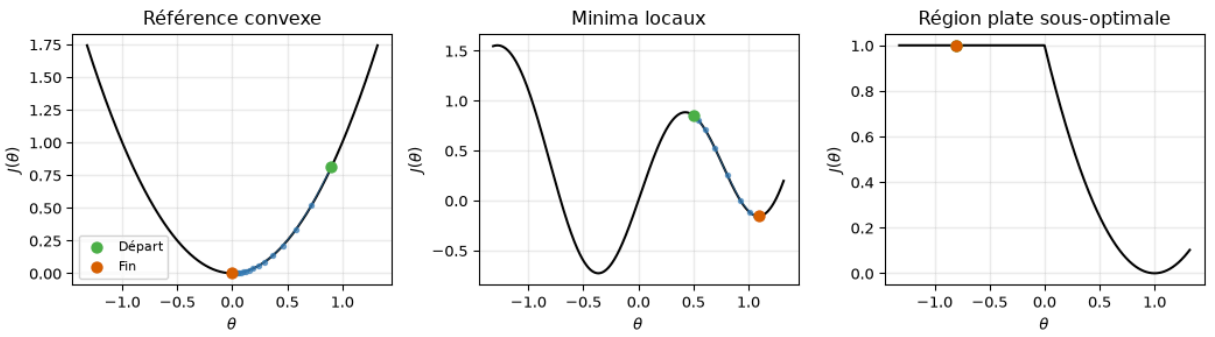
n'examine pas tout le paysage. Une région horizontale peut donc arrêter les mises à jour, même si de meilleures valeurs existent ailleurs. La figure suivante montre les trajectoires produites par la procédure de descente de gradient indiquée.

Les trois fonctions objectif sont-elles différentiables partout? Les deux premières le sont. La troisième, $J(\theta) = (\mathrm{ReLU}(\theta) - 1)^2$, présente un point anguleux à $\theta = 0$: la pente à gauche vaut 0 et celle à droite vaut -2. La dérivée n'est donc pas définie à ce point. La région plate où $\theta < 0$ est différentiable, avec une dérivée nulle.

Les cadriciels fournissent des règles de rétropropagation pour les opérations usuelles à de tels points anguleux. La fonction `torch.relu` de PyTorch utilise zéro à son point anguleux; autograd retourne donc aussi zéro pour la troisième fonction objectif à $\theta = 0$, conformément à la règle utilisée dans cet exemple. PyTorch peut ainsi calculer des valeurs pour le passage arrière des trois fonctions lorsqu'elles sont exprimées à l'aide de ses opérations sur les tenseurs. Cette convention ne rend pas la troisième fonction différentiable partout et n'aide pas la descente de gradient à quitter sa région plate. Voir PyTorch : gradients des fonctions non différentiables.

Trois paysages, trois trajectoires

In [3]:
```
fig, axes = plt.subplots(1, 3, figsize=(11, 3.2))
for ax, (title, objective, gradient, start, rate) in zip(axes, overview):
    trajectory = gradient_descent_1d(gradient, start, rate, steps=60)
    plot_landscape(objective, trajectory, ax, title)
axes[0].legend(fontsize=8)
fig.tight_layout()
plt.show()
```



Paysages de perte et descente de gradient : expériences complètes, cartes thermiques et comparaisons avec écrêtage.

La fonction convexe de référence approche son minimum. Dans l'exemple non convexe, le point initial détermine le minimum local atteint. Dans le troisième exemple, $J(\theta) = (\mathrm{ReLU}(\theta) - 1)^2$: toute valeur négative du paramètre produit une perte de 1 et un gradient nul, alors que $\theta = 1$ donne une perte nulle. Il s'agit d'une région plate sous-optimale, et non d'une fonction objectif constante partout.

Le carnet complémentaire présente aussi des fonctions objectif simplifiées singulières et discontinues. Elles illustrent des situations où la différentiabilité ordinaire fait défaut. Il faut les distinguer de l'atténuation ou de l'amplification des gradients à travers les couches d'un réseau.

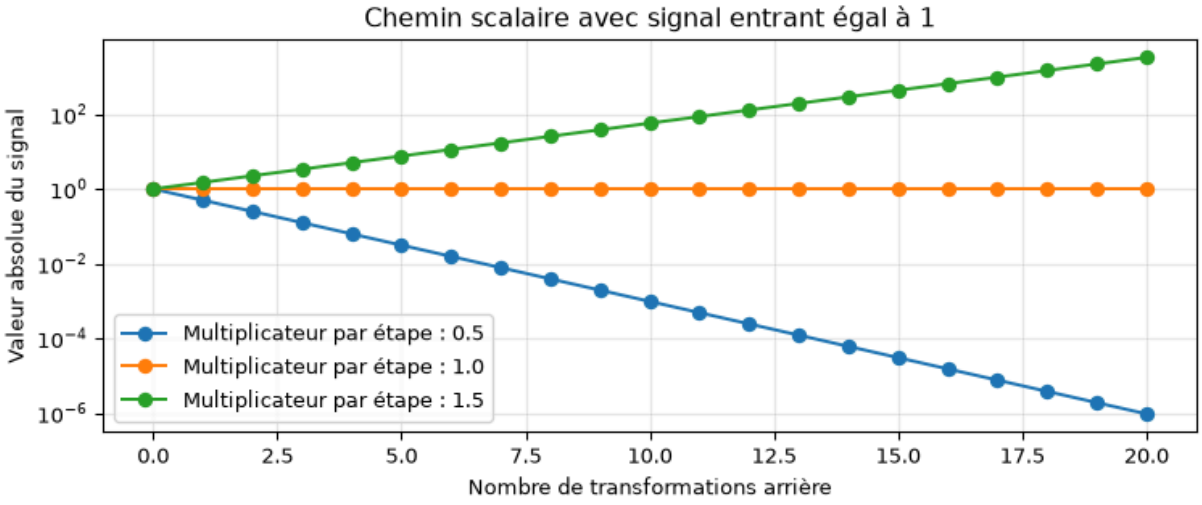
Dans ces exemples, une discontinuité correspond à un saut de la valeur de la fonction objectif. La pointe de la fonction racine carrée possède une dérivée dont la valeur absolue devient arbitrairement grande à proximité de la pointe. Ces propriétés concernent la fonction simplifiée elle-même; la section suivante étudie plutôt les produits de dérivées finies dans un réseau.

Propagation des gradients et initialisation

Que se passe-t-il sur un chemin plus long?

La présentation 13 utilisait une seule unité cachée. Que se passe-t-il lorsque de nombreuses transformations du passage arrière se composent?

In [4]:
```
distance = np.arange(21)
fig, ax = plt.subplots(figsize=(8, 3.5))
for factor in (0.5, 1.0, 1.5):
    ax.semilogy(distance, factor**distance, 'o-', label=f'Multiplicateur par
ax.set(xlabel='Nombre de transformations arrière', ylabel='Valeur absolue du
       title='Chemin scalaire avec signal entrant égal à 1')
ax.grid(alpha=0.3)
ax.legend()
fig.tight_layout()
plt.show()
```



$\delta_l = w_{l+1}\varphi'(z_l)\,\delta_{l+1}$, où $w_{l+1}\varphi'(z_l)$ est le **multiplicateur par étape**.

Le **multiplicateur par étape**, aussi appelé ici facteur local, combine un poids et une dérivée d'activation. Rappelons la notation scalaire de la présentation 13 : z_l est la

préactivation de l'unité à la couche l, w_{l+1} est le poids qui la relie à l'unité suivante et le **signal d'erreur** $\delta_l = \partial \ell / \partial z_l$ mesure la sensibilité de la perte à cette préactivation. Avec une unité par couche, la rétropropagation donne

$$\delta_l = \underbrace{w_{l+1} \varphi'(z_l)}_{q_l} \delta_{l+1}.$$

Le facteur $\varphi'(z_l)$ est la dérivée locale de l'activation, évaluée à la préactivation conservée en mémoire. Ainsi, q_l est le multiplicateur appliqué lorsque le signal progresse d'une étape vers l'entrée. Il ne s'agit ni du taux d'apprentissage ni du gradient complet d'un paramètre. Le graphique utilise délibérément le **même multiplicateur positif q à chaque étape**, à partir d'un signal de valeur absolue 1. Après d étapes arrière, la valeur absolue est q^d

> $q = 0.5$ la divise par deux à chaque étape, $q = 1$ la préserve et $q = 1.5$ l'augmente de 50 % par étape. L'axe vertical est logarithmique pour rendre visibles l'atténuation et l'amplification.

Dans un réseau réel, les facteurs dépendent de la couche et de l'exemple, peuvent être négatifs et ne sont pas nécessairement égaux. Un facteur négatif peut inverser le signe du signal; ce graphique utilise des facteurs positifs pour isoler les changements de valeur absolue.

Les paysages illustraient la géométrie locale d'une fonction objectif. Cet exemple isole un autre mécanisme : la composition de nombreuses dérivées locales peut modifier considérablement l'échelle du signal, même si chaque facteur est fini.

Cette illustration suit un seul chemin. Un réseau général additionne aussi les contributions aux embranchements, comme dans la présentation 13. La borne de 0.25 de la dérivée sigmoïde ne borne pas tous les gradients complets des paramètres, puisque les poids et d'autres chemins contribuent aussi.

Gradients évanescents

- La rétropropagation multiplie de façon répétée des **poids et des dérivées locales d'activation**.
- De petits facteurs peuvent rendre les gradients des premières couches trop faibles pour un apprentissage efficace.
- Les unités sigmoïdes saturées ont des dérivées proches de zéro.

Rappel : $\sigma'(z) = \sigma(z)(1 - \sigma(z)) \leq 0.25$.

L'exemple scalaire de la présentation 13 contenait une dérivée d'activation cachée. Un réseau plus profond introduit davantage de facteurs de ce type sur chaque chemin. La dérivée sigmoïde approche zéro pour des préactivations très positives ou très négatives;

les unités saturées peuvent donc fortement atténuer le signal propagé vers l'amont. Il s'agit du problème des gradients évanescents (*vanishing gradients*).

Une activation est **saturée** lorsque modifier son entrée produit très peu de changement à sa sortie : sa dérivée locale est alors proche de zéro. Pour une sigmoïde, cela se produit près des deux extrémités de son intervalle de sortie. **En amont** signifie vers les entrées dans le calcul arrière; **en aval** signifie vers la sortie et la perte.

Les poids entrent aussi dans ces produits et les différents chemins apportent des sommes : la borne de 0.25 de la dérivée locale d'une sigmoïde ne borne pas chaque gradient complet d'un paramètre. Les gradients peuvent diminuer ou augmenter selon les transformations combinées. Les gradients évanescents et explosifs peuvent survenir dans les réseaux à propagation avant comme dans les réseaux récurrents.

Pour une sortie sigmoïde et l'entropie croisée binaire, le signal d'erreur de sortie se simplifie en $\hat{p} - y$. Le facteur sigmoïde explicite s'y annule, mais les unités sigmoïdes cachées contribuent toujours leurs dérivées d'activation. La formule simplifiée à la sortie ne supprime donc pas le problème des couches cachées.

Gradients explosifs

- Des transformations répétées peuvent **amplifier** les signaux du passage arrière.
- De grands gradients peuvent produire de **grandes mises à jour des paramètres** et un entraînement instable.
- Une initialisation adaptée et un taux d'apprentissage raisonnable aident; l'**écrêtage des gradients** peut limiter les mises à jour.

Les gradients explosifs (*exploding gradients*) n'exigent pas une activation de dérivée infinie. Multiplier une suite de transformations finies peut suffire. Cette difficulté peut survenir dans les réseaux à propagation avant et récurrents. Les grandes dérivées près de la pointe d'une fonction scalaire relèvent d'un autre mécanisme, même si l'écrêtage peut borner une mise à jour dans les deux cas.

Fonctions d'activation et dérivées

Quelles pentes préservent un signal utile au passage arrière? ReLU résout-elle tous les problèmes?

In [5]:
```
# Attribution: https://github.com/ageron/handson-ml3/blob/main/10_neural_net

import numpy as np
import matplotlib.pyplot as plt

from scipy.special import expit as sigmoid
```

```python
def relu(z):
    return np.maximum(0, z)

def derivative(f, z, eps=0.000001):
    return (f(z + eps) - f(z - eps))/(2 * eps)

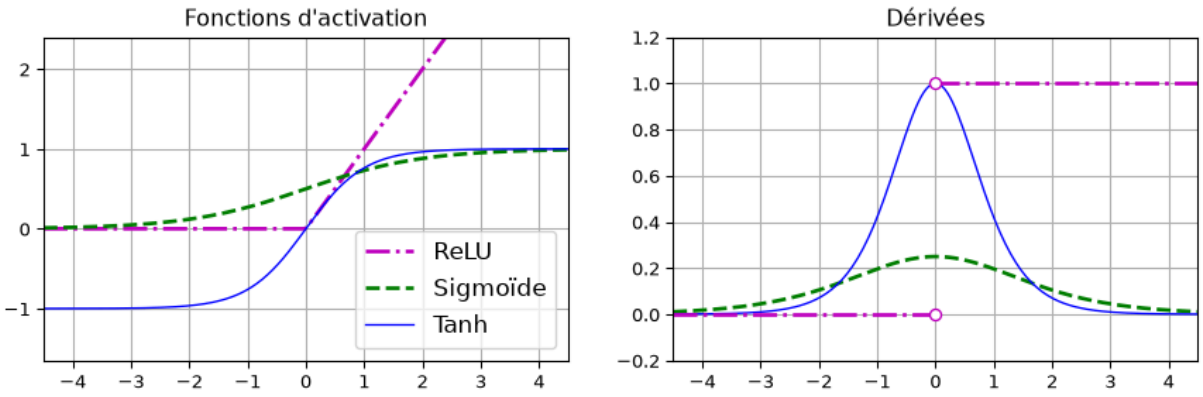
max_z = 4.5
z = np.linspace(-max_z, max_z, 200)

plt.figure(figsize=(11, 3.1))

plt.subplot(121)
plt.plot(z, relu(z), "m-.", linewidth=2, label="ReLU")
plt.plot(z, sigmoid(z), "g--", linewidth=2, label="Sigmoïde")
plt.plot(z, np.tanh(z), "b-", linewidth=1, label="Tanh")
plt.grid(True)
plt.title("Fonctions d'activation")
plt.axis([-max_z, max_z, -1.65, 2.4])
plt.gca().set_yticks([-1, 0, 1, 2])
plt.legend(loc="lower right", fontsize=13)

plt.subplot(122)
plt.plot(z, derivative(sigmoid, z), "g--", linewidth=2, label="Sigmoïde")
plt.plot(z, derivative(np.tanh, z), "b-", linewidth=1, label="Tanh")
plt.plot([-max_z, 0], [0, 0], "m-.", linewidth=2)
plt.plot([0, max_z], [1, 1], "m-.", linewidth=2)
plt.plot([0, 0], [0, 1], "mo", markersize=6, markerfacecolor="white")
plt.grid(True)
plt.title("Dérivées")
plt.axis([-max_z, max_z, -0.2, 1.2])

plt.show()
```



Géron (2022) – 10_neural_nets_with_keras.ipynb

Le choix de l'activation influence la propagation des gradients et donc l'entraînement. Il faut savoir interpréter ces pentes et le rôle de la règle de dérivation en chaîne, plutôt que dériver manuellement chaque expression.

La dérivée sigmoïde atteint un maximum de 0.25 et approche zéro aux deux extrêmes. La dérivée de $\tanh$ atteint un maximum de un à zéro et approche aussi zéro dans ses régions saturées.

Pour ReLU, la dérivée vaut zéro lorsque la préactivation est négative et un lorsqu'elle est positive. À zéro, la dérivée ordinaire n'est pas définie; les implémentations choisissent une valeur par convention, souvent zéro. Les cercles ouverts indiquent l'absence de dérivée ordinaire. L'activation peut prendre toute valeur non négative : c'est la dérivée, en dehors de zéro, qui vaut zéro ou un.

La **parcimonie** (*sparsity*) signifie que de nombreuses entrées sont exactement nulles. ReLU produit des activations parcimonieuses puisqu'elle retourne zéro pour les entrées non positives; cela décrit les activations de certains exemples, sans affirmer que les poids sont nuls. Une activation nulle pour un exemple est normale. Une unité qui demeure dans cette région pour les entrées pertinentes ne reçoit aucun gradient de la perte des données à travers son activation et peut rester inactive : c'est le problème des **ReLU mortes** (*dying ReLU*). Il s'agit d'une inactivité persistante, plutôt que d'une seule sortie nulle. Des changements des représentations en amont peuvent parfois réactiver une unité; l'inactivité n'est donc pas toujours irréversible. Voir Lu et al. (2019).

La dérivée de ReLU du côté positif évite une source d'atténuation, sans rendre le gradient complet égal à un. Les activations entrantes, les poids en aval, les autres dérivées et les sommes sur les chemins interviennent aussi. Leaky ReLU conserve une petite pente du côté négatif, ce qui réduit ce risque particulier.

Conserver un gradient du côté négatif

Que se passe-t-il si une unité ReLU reste inactive pour les exemples d'entraînement?

In [6]:
```
import numpy as np
import matplotlib.pyplot as plt

# Définir la fonction Leaky ReLU
def leaky_relu(x, alpha=0.2):
    return np.where(x > 0, x, alpha * x)

# Définir la dérivée de Leaky ReLU
def leaky_relu_derivative(x, alpha=0.2):
    return np.where(x > 0, 1, alpha)

# Générer un intervalle de valeurs d'entrée
x_values = np.linspace(-4, 4, 400)

# Calculer Leaky ReLU et sa dérivée
leaky_relu_values = leaky_relu(x_values)
leaky_relu_derivative_values = leaky_relu_derivative(x_values)

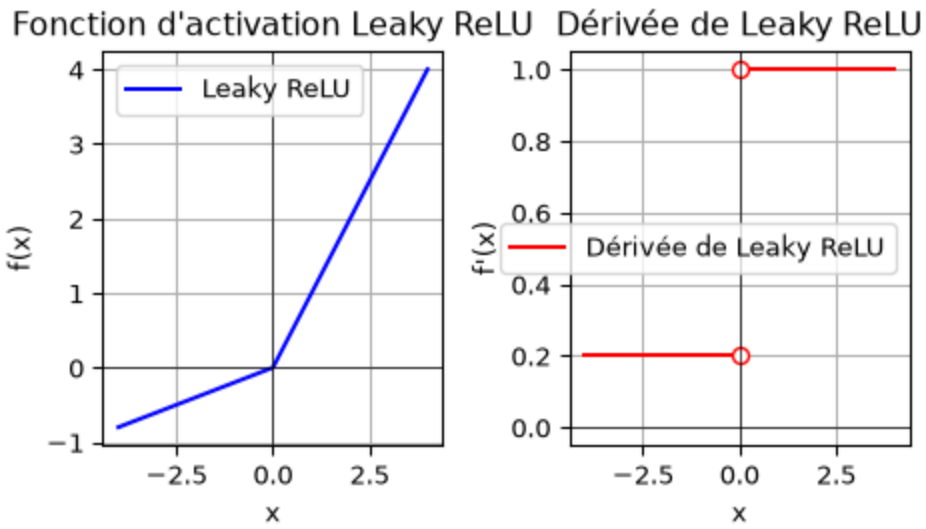
# Créer le graphique
plt.figure(figsize=(5, 3))

# Tracer Leaky ReLU
plt.subplot(1, 2, 1)
```

```
plt.plot(x_values, leaky_relu_values, label='Leaky ReLU', color='blue')
plt.title('Fonction d\'activation Leaky ReLU')
plt.xlabel('x')
plt.ylabel('f(x)')
plt.grid(True)
plt.axhline(0, color='black',linewidth=0.5)
plt.axvline(0, color='black',linewidth=0.5)
plt.legend()

# Tracer la dérivée de Leaky ReLU
plt.subplot(1, 2, 2)
plt.plot([-4, 0], [0.2, 0.2], label='Dérivée de Leaky ReLU', color='red')
plt.plot([0, 4], [1, 1], color='red')
plt.plot([0, 0], [0.2, 1], 'o', color='red', markerfacecolor='white')
plt.title('Dérivée de Leaky ReLU')
plt.xlabel('x')
plt.ylabel("f'(x)")
plt.grid(True)
plt.axhline(0, color='black',linewidth=0.5)
plt.axvline(0, color='black',linewidth=0.5)
plt.legend()

# Afficher les graphiques
plt.tight_layout()
plt.show()
```



Leaky ReLU, une variante de l'activation ReLU habituelle, atténue le problème des *unités ReLU mortes*. Pour les entrées négatives, elle introduit une composante linéaire dont la pente est contrôlée par le paramètre `negative_slope`.

Leaky ReLU conserve une dérivée non nulle du côté négatif, ce qui réduit le risque d'inactivité persistante causée par un gradient d'activation nul. À zéro, sa dérivée ordinaire n'est pas définie si les deux pentes diffèrent; l'implémentation choisit une convention. Les cercles ouverts distinguent ce point mathématique de la valeur choisie dans le code.

```
import keras

leaky_relu = keras.layers.LeakyReLU(negative_slope=0.2)
dense = keras.layers.Dense(50, activation=leaky_relu,
kernel_initializer="he_normal")
```

Voir les fonctions d'activation de Keras pour d'autres choix.

Pourquoi ne pas initialiser tous les poids à la même valeur?

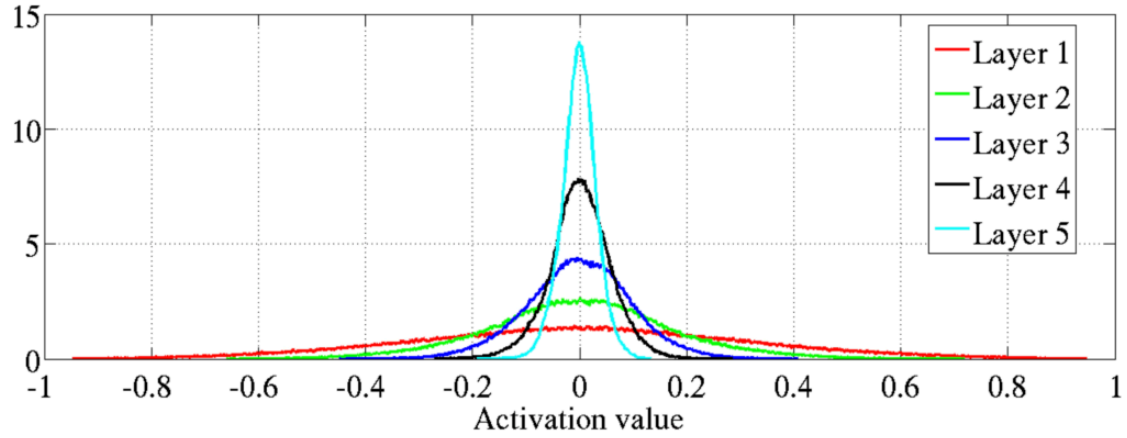
Des **poids** initialisés aléatoirement brisent la symétrie entre les unités. Les **biais** peuvent être initialisés à zéro.

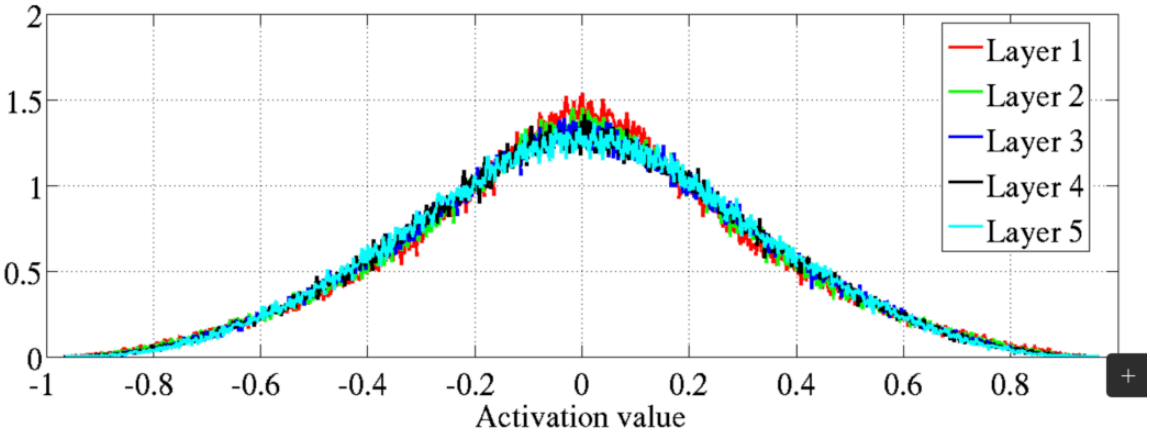
Des unités aux paramètres initiaux identiques et aux rôles identiques peuvent recevoir les mêmes gradients. L'initialisation aléatoire des poids leur donne des calculs de départ différents. Une échelle d'initialisation adaptée à l'activation favorise la propagation des signaux; elle ne garantit ni convergence ni performance optimale.

Glorot et Bengio

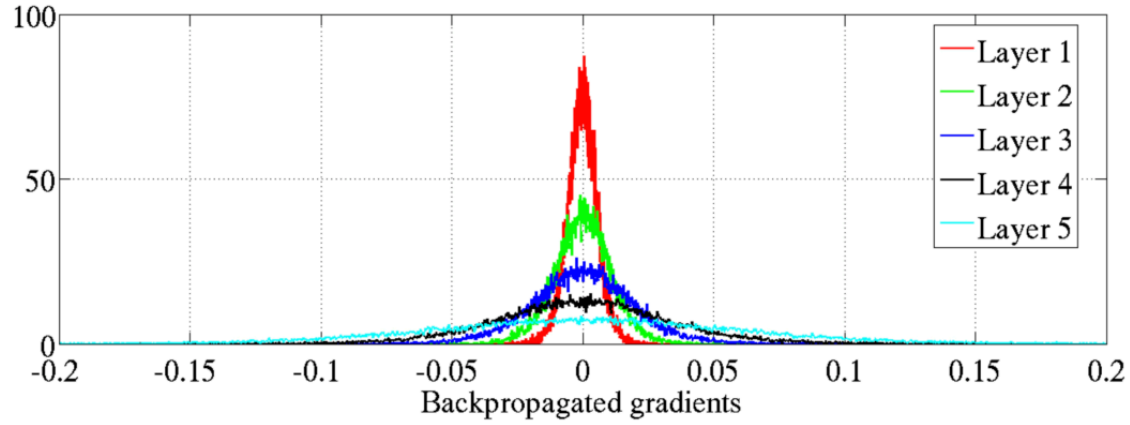
Des poids aléatoires brisent la symétrie. Leur échelle importe-t-elle?

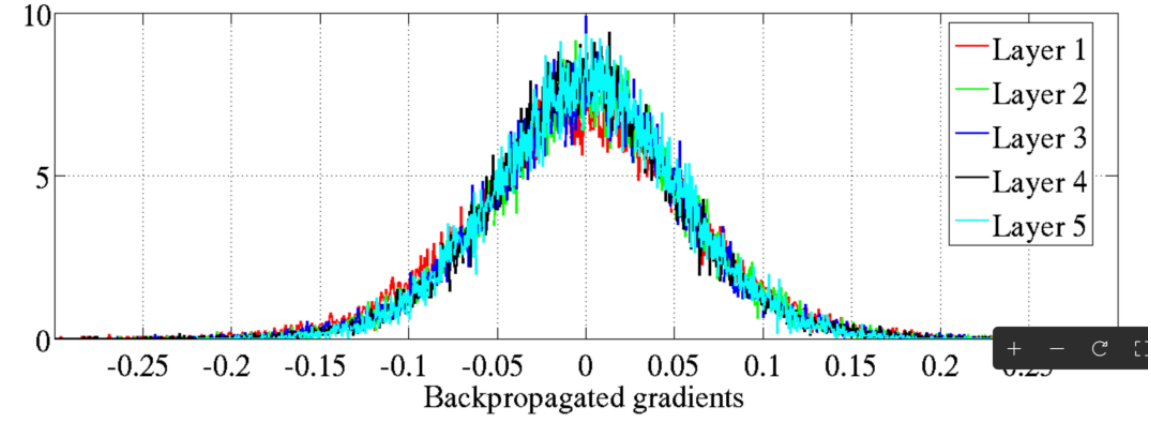
Activations





Signaux du passage arrière





Glorot et Bengio (2010), page 254.

Ces figures comparent une initialisation habituelle (en haut) à l'initialisation normalisée proposée par Glorot et Bengio (en bas), pour un réseau d'unités $\tanh$ (Glorot et Bengio 2010, 254). La figure 6 présente les histogrammes des activations et la figure 7 ceux des gradients rétropropagés. Avec l'initialisation habituelle, les activations se concentrent davantage près de zéro dans les dernières couches, tandis que les gradients rétropropagés se concentrent davantage près de zéro à proximité de l'entrée. Dans ces expériences, l'initialisation normalisée réduit les différences entre les couches.

Ces distributions correspondent à la configuration rapportée; elles n'établissent pas une règle universelle selon laquelle des gradients évanescents impliqueraient toujours de faibles activations au passage avant. Une sigmoïde saturée peut avoir une activation proche de un et une dérivée proche de zéro. L'article distingue aussi les signaux rétropropagés des gradients des poids; leurs distributions selon la couche ne sont pas nécessairement identiques.

L'initialisation normale de Xavier/Glorot équilibre les dimensions d'entrée et de sortie de la couche avec $\mathrm{Var}(W) = 2/(n_{\text{in}} + n_{\text{out}})$. Il s'agit de l'initialisation aléatoire mise à l'échelle déjà utilisée dans `SimplerMLP`. Ici, n_{in} et n_{out} comptent les entrées et les sorties de la couche. La variance concerne chaque poids échantillonné; l'écart-type de la distribution normale est la racine carrée de cette variance.

Initialisation de He

Pour les couches cachées ReLU, l'initialisation normale de He utilise

$$\mathrm{Var}(W) = \frac{2}{n_{\text{in}}}.$$

```
def he_init(rng, fan_in, fan_out):
    std = np.sqrt(2.0 / fan_in)
    return rng.normal(0.0, std, size=(fan_in, fan_out))
```

Aussi appelée initialisation de Kaiming.

Cette mise à l'échelle tient compte de l'effet du redresseur sur la variance du signal. `SimpleMLP` utilisera l'initialisation de He pour les couches cachées ReLU et celle de Xavier/Glorot pour les couches sigmoïdes, y compris la sortie. Ce sont des règles d'initialisation, sans garantie sur l'ensemble de la trajectoire d'entraînement. Voir He et al. (2015) pour l'analyse des redresseurs.

Quels choix favorisent la propagation des gradients?

- **Autres fonctions d'activation** : unité linéaire rectifiée (**ReLU**) et variantes, dont **Leaky ReLU**, **Parametric ReLU** et **Exponential Linear Unit**.

- **Initialisation des poids** : Xavier (Glorot) ou He.

Les fonctions d'activation et l'initialisation influencent la propagation des signaux dans les deux directions. ReLU évite la saturation pour les préactivations positives, mais sa dérivée nulle du côté négatif crée le risque d'inactivité persistante illustré plus tôt. L'activation et l'échelle d'initialisation agissent ensemble; aucune ne garantit des gradients stables dans un réseau arbitrairement profond. Les **couches de normalisation** et les **connexions résiduelles** offrent d'autres approches, au-delà de cette implémentation. Même avec de bonnes conditions initiales, des mises à jour exceptionnellement grandes restent possibles, ce qui motive le contrôle de la mise à jour elle-même.

Écrêtage des gradients

Comment limiter une mise à jour de descente de gradient trop grande tout en préservant sa direction?

Pour un vecteur gradient g et un seuil $c > 0$:

$$\tilde{g} = \begin{cases} g, & \|g\|_2 \leq c, \\ c\, g / \|g\|_2, & \|g\|_2 > c. \end{cases}$$

La mise à jour utilise $\tilde{g}$. Sa norme est bornée par c.

```
optimizer = keras.optimizers.SGD(learning_rate=0.01,
global_clipnorm=1.0)
```

L'écrêtage des gradients par norme globale (*global-norm gradient clipping*) redimensionne le gradient de l'ensemble des paramètres lorsque nécessaire, tout en préservant sa direction. Il diffère de l'écrêtage de chaque composante séparément; les deux coïncident pour un gradient scalaire. Avec un taux d'apprentissage α, la mise à jour de descente de gradient correspondante a une norme d'au plus αc.

Ici, g regroupe les dérivées par rapport à tous les paramètres dans un même vecteur; chaque composante correspond à un poids ou à un biais. Sa **norme L2 ou euclidienne** est $\|g\|_2 = \sqrt{\sum_j g_j^2}$, c'est-à-dire sa longueur. Le seuil c borne cette longueur combinée, plutôt que chaque composante séparément. Les définitions générales des normes apparaissent plus loin, dans la section sur la régularisation.

L'écrêtage ne corrige pas les gradients évanescents et ne garantit pas la convergence. Le carnet complémentaire compare les mises à jour avec et sans écrêtage dans les mêmes conditions et présente un exemple à pointe où des pas constants continuent d'osciller. L'initialisation, l'activation, l'écrêtage et l'évolution du taux d'apprentissage traitent différents aspects de l'entraînement.

Décroissance du taux d'apprentissage

Des pas plus petits peuvent-ils aider plus tard dans l'entraînement? Et si on les réduit trop tôt?

À l'époque $t = 1, 2, \ldots$, avec un facteur de décroissance $0 < \gamma < 1$:

$$\alpha_t = \alpha_1 \gamma^{t-1}.$$

```
if self.lr_decay is not None:
    self.lr = self.base_lr * self.lr_decay ** (ep - 1)
```

La première époque utilise le taux d'apprentissage initial; les suivantes utilisent des pas progressivement plus petits. Avec `lr_decay=None`, le taux reste constant. La décroissance modifie la taille du pas de l'optimiseur, plutôt que les formules des dérivées ou la fonction objectif. Elle diffère de la régularisation L2 et de la décroissance des poids. Réduire le taux trop rapidement peut empêcher des progrès utiles; cela ne corrige pas les gradients évanescents.

Une **époque** (*epoch*) désigne ici un passage sur tous les exemples d'entraînement, éventuellement répartis en mini-lots. La **décroissance des poids** (*weight decay*) consiste à réduire directement les poids lors des mises à jour des paramètres.

Couches de sortie

Changer l'activation de sortie?

Nous avons remplacé une sigmoïde cachée par ReLU. Faut-il faire de même à la sortie?

Pour la **régression**, la sortie doit respecter les dimensions et l'intervalle de valeurs de la cible :

- **Nombre de neurones de sortie** :
  - 1 par dimension
- **Fonction d'activation de sortie** :
  - Linéaire pour les cibles sans contrainte; ReLU/softplus pour les cibles non négatives; sigmoïde/tanh pour les cibles bornées.
- **Fonction de perte** :
  - MeanSquaredError

Dans un problème de détection d'objets, déterminer la **boîte englobante** (*bounding box*) illustre une tâche de régression à sortie multidimensionnelle.

La section précédente modifiait les activations cachées pour influencer la propagation des gradients. La sortie a une autre obligation : ses valeurs doivent représenter les

prédictions requises. Remplacer la sigmoïde de sortie par ReLU modifie les sorties possibles et leur interprétation, plutôt que d'améliorer simplement une dérivée interne.

Dans un réseau à propagation avant, les activations cachées sont choisies surtout pour leurs effets sur la performance et la convergence, tandis que l'activation de sortie dépend des exigences de la tâche.

- **Couches cachées :**

  La fonction d'activation, par exemple sigmoïde, tanh ou ReLU, influence surtout la *dynamique d'entraînement* : propagation des gradients, forme de la non-linéarité et vitesse de convergence. Le choix est généralement empirique et guidé par la performance, la stabilité numérique et le comportement de l'optimisation.

- **Couche de sortie :**

  La fonction d'activation est déterminée par la **nature de la tâche de prédiction** :

  - *Régression* : linéaire, ReLU ou softplus, selon les contraintes de valeurs
  - *Classification binaire* : sigmoïde
  - *Classification multiclasse* : softmax
  - *Classification multiétiquette* : sigmoïde par unité de sortie

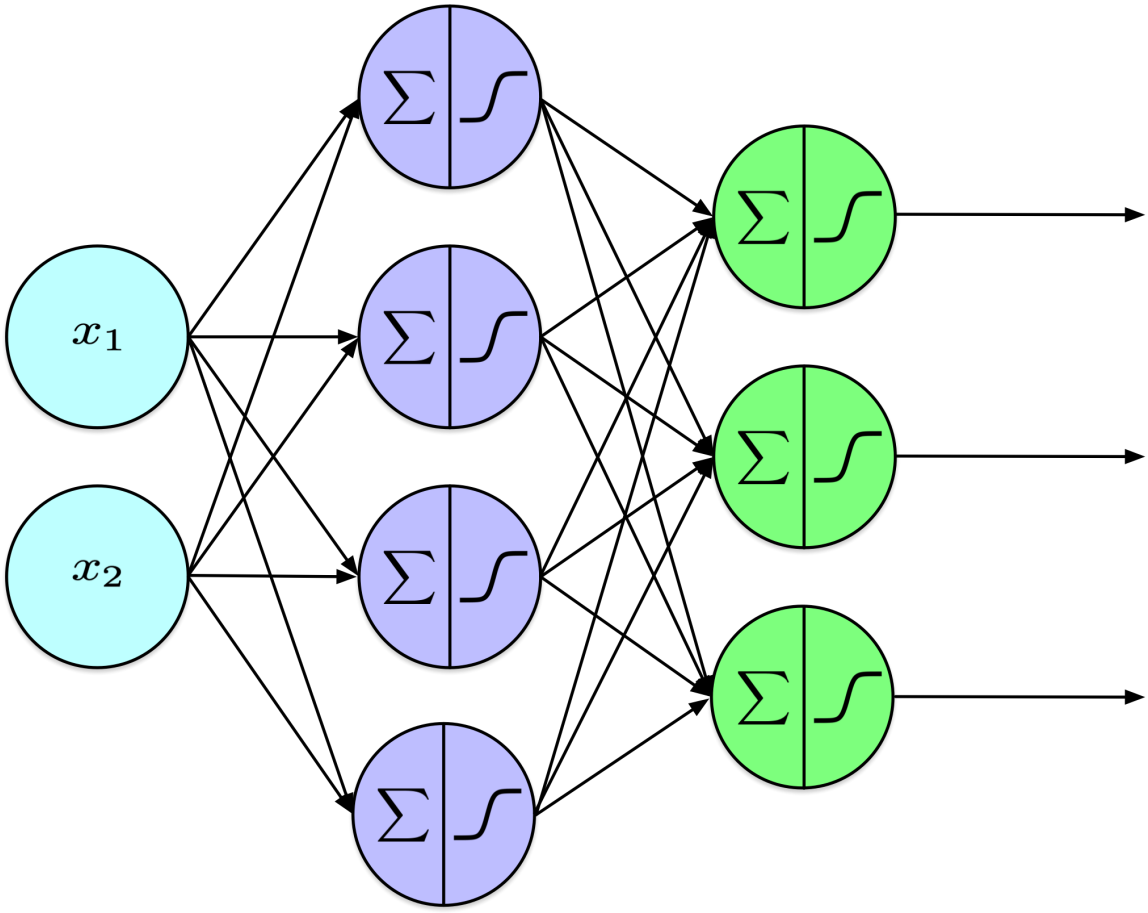
Softplus est la fonction lisse $\mathrm{softplus}(z) = \log(1 + e^z)$. Elle produit des valeurs strictement positives pour des entrées finies et approche zéro pour des entrées très négatives; elle constitue donc une option pour une régression à sorties positives. ReLU peut aussi représenter un zéro exact. Une activation de sortie **linéaire** correspond à l'identité : la sortie est le score affine lui-même. Voir les définitions des activations de Keras.

Voici des exemples de **régression à sorties multiples** (2 à 4 sorties) :

- **2 sorties :**
  - Prédire la **latitude et la longitude** d'un lieu à partir d'une image.
  - Estimer la **largeur et la hauteur** d'une boîte englobante en détection d'objets.
  - Prévoir simultanément la **température et l'humidité**.
- **3 sorties :**
  - Prédire les **coordonnées x, y, z** d'un point dans l'espace, par exemple une articulation de la main.
  - Estimer les **valeurs de couleur RVB** à partir de mesures spectrales.
- **4 sorties :**
  - Prédire les **coordonnées d'une boîte englobante**, $(x_{min}, y_{min}, x_{max}, y_{max})$, en détection d'objets.

Ces probabilités décrivent-elles un choix exclusif?

Des sigmoïdes distinctes donnent $[0.8,\ 0.7,\ 0.1]$. Plusieurs étiquettes peuvent-elles s'appliquer? Une seule classe peut-elle s'appliquer?

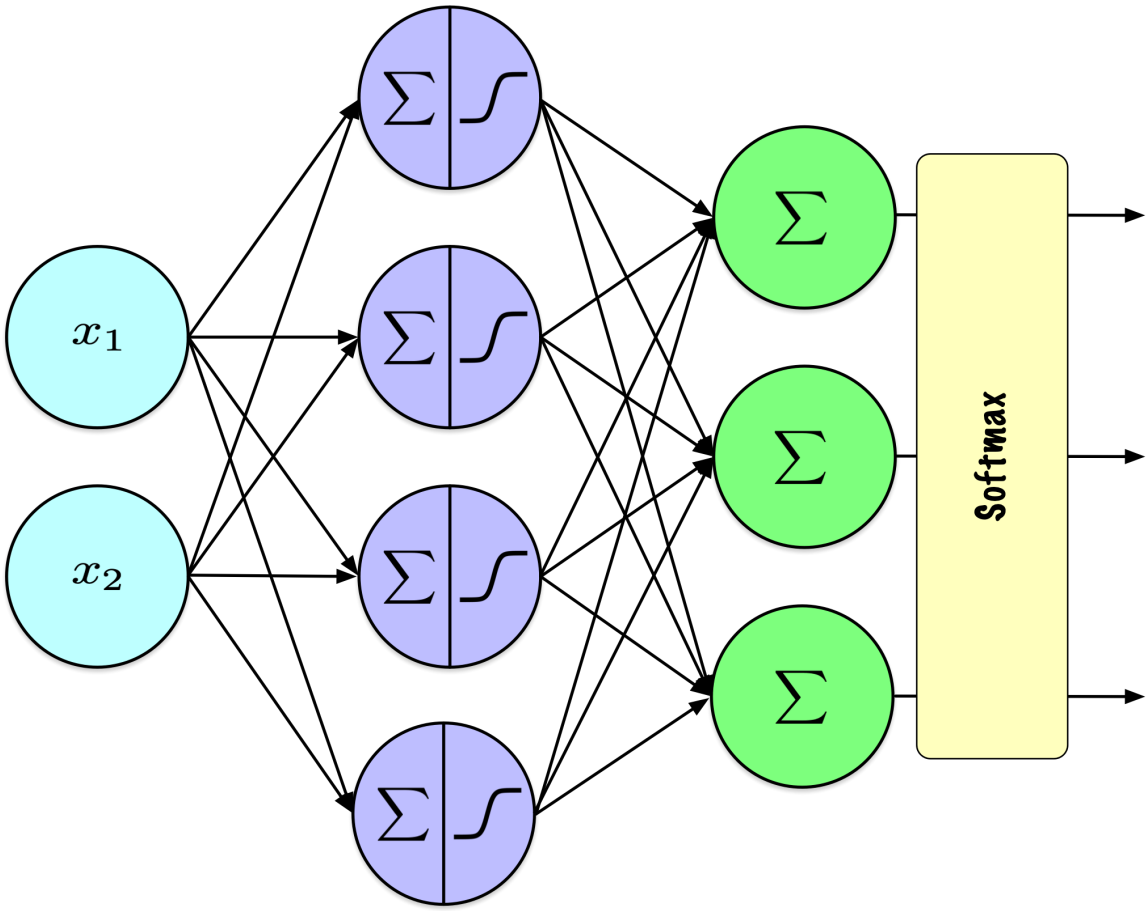


Des sorties sigmoïdes indépendantes conviennent aux prédictions multiétiquettes; leurs probabilités n'ont pas à totaliser un.

Les valeurs proposées totalisent 1.6. Elles peuvent représenter les probabilités d'étiquettes distinctes qui coexistent, par exemple plusieurs objets présents dans une image. Elles ne constituent pas directement une distribution sur un ensemble exhaustif de classes mutuellement exclusives, dont les probabilités doivent totaliser un. Cette différence concerne le sens des sorties, et pas seulement le nombre d'unités de sortie.

Une distribution commune à la sortie

Quelles propriétés la sortie doit-elle avoir lorsqu'une seule des K classes est correcte?



Softmax garantit que les sorties d'activation sont comprises entre 0 et 1 et que leur somme vaut 1.

Un **logit** de sortie est un score réel sans contrainte, avant que la sigmoïde ou softmax finale transforme les scores en probabilités. Dans le diagramme, les logits sont les préactivations de la couche de sortie. Softmax s'applique à tout le vecteur de sortie : chaque probabilité dépend de tous les logits, par le dénominateur commun. Pour une tâche multiétiquette, les sigmoïdes sont plutôt calculées élément par élément et leurs sorties n'ont pas à totaliser un.

Les propriétés recherchées motivent cette construction : les sorties doivent être non négatives, totaliser un et permettre le calcul des gradients. Softmax est une manière différentiable courante d'obtenir cette distribution à partir de scores sans contrainte; ces exigences ne déterminent toutefois pas à elles seules sa formule exponentielle.

La fonction argmax ne convient pas à l'optimisation par gradient : elle est constante par morceaux, avec des dérivées nulles en dehors des égalités et des dérivées non définies aux frontières pertinentes. Softmax offre une interprétation probabiliste et une dérivée calculable, ce qui la rend plus adaptée à ces applications.

La fonction argmax peut être appliquée *a posteriori* à un réseau entraîné pour prédire une classe.

Comme dans la présentation 11, **argmax** retourne l'indice d'une plus grande entrée. Elle choisit une classe, tandis que softmax retourne tout le vecteur des probabilités de classe.

Des scores à une distribution de probabilités

La fonction **softmax** est une **fonction d'activation** utilisée en **classification multiclasse** pour convertir un vecteur de scores bruts en **probabilités dont la somme vaut 1**.

Pour K logits de sortie $\mathbf{z} = [z_1, z_2, \ldots, z_K]$:

$$\hat{p}_k = \text{softmax}(\mathbf{z})_k = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}$$

Ici, $\hat{p}_k$ est la probabilité prédite pour la classe k.

Les logits de sortie sont des scores réels. L'exponentiation rend leurs valeurs transformées positives et la normalisation porte la somme des probabilités à un. Des logits égaux donnent une probabilité $1/K$ à chaque classe. Ajouter une même constante à tous les logits ne change pas les probabilités.

Softmax préserve l'ordre : le plus grand logit et la plus grande probabilité désignent la même classe. Les rapports de probabilités satisfont $\hat{p}_i / \hat{p}_j = e^{z_i - z_j}$. Ces scores relatifs ne garantissent pas une prédiction correcte. Une distribution de probabilités peut généralement contenir des zéros; la positivité est une propriété de softmax mathématique pour des logits finis.

Que signifient les écarts entre les scores?

Quelle classe l'emporte? Comment l'écart entre les scores influence-t-il sa probabilité?

z_1	z_2	z_3	$\hat{p}_1$	$\hat{p}_2$	$\hat{p}_3$	$\sum$
1.47	-0.39	0.22	**0.69**	0.11	0.20	1.00
5.00	**6.00**	4.00	0.24	**0.67**	0.09	1.00
0.90	0.80	**1.10**	0.32	0.29	**0.39**	1.00
-2.00	**2.00**	-3.00	0.02	**0.98**	0.01	1.00

Valeurs de softmax pour un vecteur de longueur 3.

1. **Préservation de l'ordre relatif** : si une entrée est plus grande qu'une autre, la sortie softmax correspondante est aussi plus grande.

2. **Interprétation probabiliste** : chaque valeur est comprise entre 0 et 1. Les sorties sont normalisées pour totaliser un, ce qui permet de les interpréter comme des probabilités.

3. **Écarts relatifs** : lorsque les écarts entre les logits sont petits, les probabilités restent proches de la distribution uniforme. Si tous les logits sont identiques, chaque probabilité vaut $\frac{1}{K}$.

4. **Arrondi** : dans la dernière ligne, les probabilités affichées peuvent totaliser 1.01, car chaque entrée a été arrondie séparément. Les probabilités non arrondies totalisent un. La stabilité numérique exige le calcul décalé présenté ci-dessous.

Ces propriétés rendent softmax particulièrement utile pour les tâches de classification multiclasse en apprentissage automatique.

Calculer softmax de manière stable

Que se passe-t-il si les logits valent 1000, 1001 et 999?

Soustraire le plus grand logit ne change pas les probabilités :

$$\hat{p}_k = \frac{e^{z_k - m}}{\sum_j e^{z_j - m}}, \qquad m = \max_j z_j.$$

Exponentier directement de très grands scores positifs peut causer un dépassement de capacité. Soustraire le maximum évite ce dépassement. De très petites probabilités peuvent néanmoins subir un sous-dépassement; les bibliothèques utilisées en pratique combinent donc habituellement la perte aux logits à l'aide de calculs log-sum-exp stables. Voir softmax dans SciPy.

Un **dépassement de capacité** (*overflow*) se produit lorsqu'une valeur calculée dépasse l'intervalle de la représentation en virgule flottante; un **sous-dépassement** (*underflow*) peut arrondir à zéro un résultat non nul suffisamment petit. Un calcul **numériquement stable** évite les pertes inutiles de précision ou d'étendue causées par les opérations intermédiaires.

Log-sum-exp désigne la fonction $\log\left(\sum_j e^{z_j}\right)$. Elle peut être évaluée sous la forme décalée

$$\log\left(\sum_j e^{z_j}\right) = m + \log\left(\sum_j e^{z_j - m}\right), \qquad m = \max_j z_j.$$

Une implémentation combinée de l'entropie croisée peut utiliser cette expression au lieu de prendre le logarithme d'une probabilité déjà arrondie à zéro par sous-dépassement. Voir logsumexp dans SciPy.

Si la dernière couche Dense retourne des logits, utiliser une perte d'entropie croisée configurée avec `from_logits=True`. Si elle retourne des probabilités softmax, utiliser `from_logits=False`. Appliquer softmax, puis déclarer que les valeurs sont des logits, modifie la fonction objectif.

L'annexe présente un exemple exécutable du calcul décalé de softmax.

Limites

Quelles limites pouvez-vous proposer?

Notre classifieur Fashion-MNIST reçoit l'image d'un **7** manuscrit. Que prédira-t-il?

Softmax répartit toute la probabilité entre les **classes connues**. Aucune sortie **« aucune de ces classes »** n'est prévue.

Le classifieur Fashion-MNIST possède des sorties pour des classes de vêtements, et non pour des chiffres manuscrits. Face à un 7 manuscrit, il produit quand même des probabilités pour ces classes de vêtements. Appliquer argmax choisit l'une d'elles, même si aucune ne décrit correctement l'entrée. Softmax construit un vecteur de probabilités; argmax prend la décision de classe.

Un exemple d'une classe absente de la tâche d'entraînement est une entrée **hors distribution** (*out-of-distribution*). Une telle entrée peut recevoir une forte probabilité prédite pour une classe connue. Les probabilités totalisent un à cause de la transformation de sortie, et non parce que le modèle a établi qu'une de ses classes connues s'applique.

L'utilisation de softmax suivie d'argmax ne produit donc aucune réponse automatique « je ne sais pas ». Une application peut ajouter une règle qui rejette certaines entrées au lieu de retourner une classe. Par exemple, elle peut comparer la plus grande probabilité prédite à un seuil. Cela peut aider, mais des entrées inhabituelles peuvent encore recevoir de fortes probabilités et échapper au rejet. Voir Hendrycks et Gimpel, *A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks*.

Peut-on se fier aux probabilités?

Parmi de nombreuses prédictions faites avec environ **90 % de confiance**, quelle proportion devrait être correcte?

Environ **90 %**, si le modèle est **bien calibré**.

Des probabilités qui totalisent un ne garantissent pas une bonne calibration.

La **confiance** désigne ici la plus grande probabilité de classe prédite, associée à la classe choisie par argmax. La **calibration des probabilités** (*probability calibration*) concerne l'accord entre les probabilités prédites et les fréquences observées. Parmi de nombreux exemples pour lesquels la classe choisie reçoit une probabilité proche de 0.9, un classifieur bien calibré devrait avoir raison environ 90 % du temps. Cet accord devrait aussi tenir aux autres niveaux de confiance. Il s'agit d'une propriété de groupes de prédictions, sans garantie pour un exemple individuel.

L'exactitude mesure la fréquence à laquelle la classe choisie est correcte. La calibration demande si la confiance annoncée correspond à cette fréquence observée. Un classifieur peut avoir une bonne exactitude tout en étant trop confiant. La calibration doit être évaluée sur des données réservées et représentatives de l'utilisation prévue; la normalisation par softmax ne suffit pas. Voir Guo et al., *On Calibration of Modern Neural Networks*.

La calibration et la reconnaissance des classes inhabituelles sont liées, mais distinctes. Une bonne calibration sur des données familières ne garantit pas que les entrées de classes inédites seront détectées ou rejetées.

Pour approfondir, l'**apprentissage profond évidentiel** (*evidential deep learning*) explore l'apprentissage de la quantité d'éléments probants qui appuient une classification, en complément des probabilités de classe. Voir Sensoy, Kaplan et Kandemir, *Evidential Deep Learning to Quantify Classification Uncertainty*. Ses estimations d'incertitude doivent être évaluées; des recherches ultérieures ont relevé des limites des méthodes existantes. Voir Shen et al., *Are Uncertainty Quantification Capabilities of Evidential Deep Learning a Mirage?*.

Même classe prédite, même perte?

La vraie classe est Setosa. Les deux prédictions la choisissent :

- $[0.25,\ \mathbf{0.51},\ 0.24]$
- $[0.005,\ \mathbf{0.99},\ 0.005]$

L'**entropie croisée** récompense la probabilité attribuée à la vraie classe :

$$\ell = -\sum_{k=1}^{K} y_k \log(\hat{p}_k)$$

Cible encodée en un seul 1 (*one-hot*) : y. Probabilités de classe prédites : $\hat{p}_k$.

Les deux vecteurs ont leur plus grande composante à la position de Setosa. L'exactitude traite donc ces prédictions de la même façon, tandis qu'une fonction objectif fondée sur les probabilités peut les distinguer. L'entropie croisée donne les pertes $-\log(0.51) \approx 0.6733$ et $-\log(0.99) \approx 0.0101$. La perte plus faible récompense une

probabilité plus grande pour la vraie classe. Cela rappelle l'utilisation, dans la présentation 12, des probabilités de `forward` plutôt que des étiquettes seuillées de `predict` pour calculer la BCE.

- La cible y est un vecteur de longueur K encodé en un seul 1 (*one-hot*) : la composante de la vraie classe vaut 1 et toutes les autres valent 0.
- Dans la somme sur les classes, seul le terme associé à la vraie classe contribue donc une valeur non nulle.
- La perte d'entropie croisée d'un exemple vaut ainsi $-\log(\hat{p}_k)$, où $\hat{p}_k$ est la probabilité prédite pour la vraie classe.
- La probabilité $\hat{p}_k$ provient de softmax appliquée à la couche de sortie du réseau.

Entropie croisée : un exemple détaillé

- **Problème de classification** : 3 classes
  - Versicolour, Setosa, Virginica.
- **Encodage en un seul 1** :
  - Setosa = $[0, 1, 0]$.
- **Sorties softmax et perte** :
  - $[0.22, \mathbf{0.7}, 0.08]$: perte = $-\log(0.7) = 0.3567$.
  - $[0.7, \mathbf{0.22}, 0.08]$: perte = $-\log(0.22) = 1.5141$.
  - $[0.7, \mathbf{0.08}, 0.22]$: perte = $-\log(0.08) = 2.5257$.

Parmi les sorties softmax, l'entropie croisée ne retient que la composante $k = 2$ (Setosa), puisque les autres entrées du vecteur cible sont nulles. Ici, les indices mathématiques des classes vont de 1 à 3. La composante pertinente est en gras. Une plus grande probabilité pour la vraie classe donne une perte plus faible; les trois exemples donnent respectivement 0.3567, 1.5141 et 2.5257.

Comment pénaliser les erreurs faites avec confiance?

In [7]:
```
import numpy as np
import matplotlib.pyplot as plt

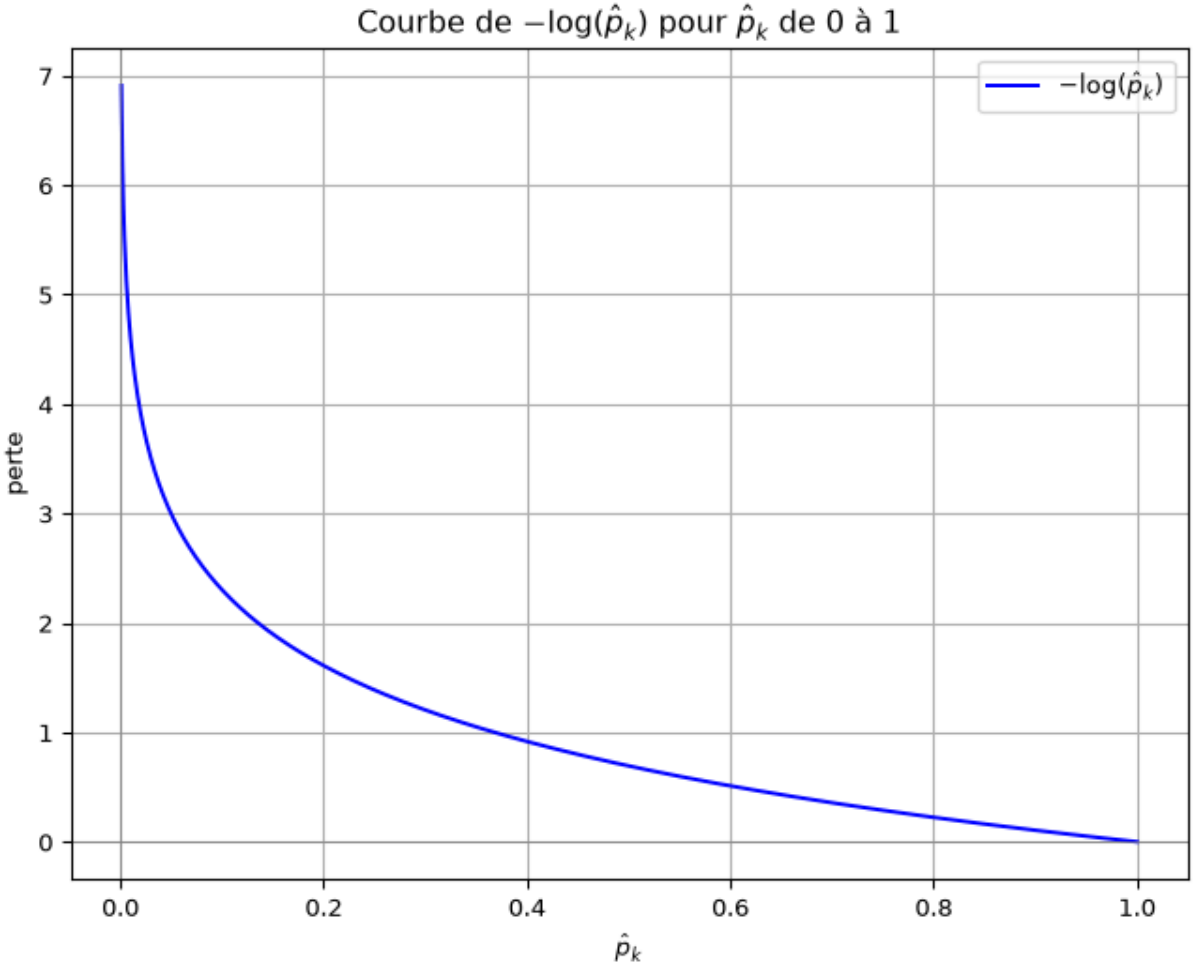
# Générer des valeurs de p strictement positives jusqu'à 1
p_values = np.linspace(0.001, 1, 1000)

# Calculer le logarithme naturel de chaque valeur de p
ln_p_values = - np.log(p_values)

# Tracer le graphique
plt.figure(figsize=(8, 6))
plt.plot(p_values, ln_p_values, label=r'$-\log(\hat p_k)$', color='b')
```

```
# Ajouter les étiquettes et le titre
plt.xlabel(r'$\hat p_k$')
plt.ylabel(r'perte')
plt.title(r'Courbe de $-\log(\hat p_k)$ pour $\hat p_k$ de 0 à 1')
plt.grid(True)
plt.axhline(0, color='gray', lw=0.5)  # Ajouter une ligne horizontale à y=0
plt.axvline(0, color='gray', lw=0.5)  # Ajouter une ligne verticale à x=0

# Afficher le graphique
plt.legend()
plt.show()
```



- Dans la somme, seul le terme où $y_k = 1$ contribue une valeur non nulle.
- À cause du signe négatif devant la somme, la valeur de la fonction est $-\log(\hat{p}_k)$.
- Si la probabilité $\hat{p}_k$ approche 1, la perte approche zéro, ce qui indique une faible pénalité.
- Si $\hat{p}_k$ approche plutôt 0, indiquant une prédiction incorrecte, la perte tend vers l'infini. Cela pénalise fortement une probabilité très faible pour la vraie classe, sans garantir à soi seul une convergence plus rapide.

D'un exemple à un jeu de données

Pour un jeu de N exemples, la **perte moyenne d'entropie croisée** sur tous les exemples se calcule ainsi :

$$J = -\frac{1}{N}\sum_{i=1}^{N}\sum_{k=1}^{K} y_{i,k}\log(\hat{p}_{i,k})$$

où :

- i désigne les différents **exemples** du jeu de données.
- $y_{i,k}$ et $\hat{p}_{i,k}$ sont respectivement les **probabilités réelles** et **prédites** de la classe k pour l'exemple i.

Qu'est-ce qui change au passage arrière?

- **Étiquettes de classe entières** : utiliser l'entropie croisée catégorielle à étiquettes entières (*sparse categorical cross-entropy*).
- **Cibles encodées en un seul 1** : utiliser l'entropie croisée catégorielle.
- Avec softmax et l'entropie croisée catégorielle, le signal de sortie d'un exemple est

$$\frac{\partial \ell}{\partial z_k} = \hat{p}_k - y_k.$$

```
output_layer = keras.layers.Dense(10)  # Logits : pas de softmax
ici.
loss = keras.losses.SparseCategoricalCrossentropy(from_logits=True)
```

L'équation utilise une cible encodée en un seul 1. Une perte à étiquettes entières reçoit l'indice de la vraie classe et calcule une perte équivalente sans stocker ce vecteur. C'est l'équivalent multiclasse du signal de sortie sigmoïde/BCE de la présentation 13. Il ne faut pas multiplier le signal déjà simplifié par une dérivée d'activation supplémentaire. Pour les lots, on moyenne une seule fois les gradients des paramètres sur les exemples, comme précédemment.

Dans l'**entropie croisée catégorielle à étiquettes entières**, le mot anglais « sparse » désigne cet encodage compact des cibles. Il ne signifie pas que les poids du modèle sont parcimonieux.

Les probabilités $\hat{p}_k$ ne sont pas des décisions de classe. Argmax donne l'étiquette prédite. `SimpleMLP`, présenté plus loin, conserve une sortie sigmoïde unique et la BCE; le carnet MNIST utilise Keras pour le modèle à dix classes.

Associer sorties et pertes de classification

Tâche	Unités de sortie	Activation	Perte
Binaire	Une	Sigmoïde	Entropie croisée binaire
Multiétiquette	Une par étiquette	Sigmoïdes distinctes	Entropie croisée binaire
Multiclasse	Une par classe	Softmax commune	Entropie croisée catégorielle

La tâche détermine le sens des sorties et la perte des données à minimiser.

Ce tableau regroupe les configurations de sorties probabilistes présentées ci-dessus. Un modèle multiclasse Keras peut aussi retourner des logits et utiliser une perte catégorielle avec `from_logits=True` ; la variante à étiquettes entières reçoit les indices des classes. Ces choix définissent la fonction objectif liée aux données. Même un objectif approprié peut être optimisé au-delà du point où la performance sur de nouveaux exemples est la meilleure, ce qui motive les courbes de validation de la section suivante.

Vidéo complémentaire : argmax et softmax

https://www.youtube.com/watch?v=KpKog-L9veg

Cette vidéo complémentaire reprend la distinction entre choisir une classe et construire des probabilités de classe différentiables. La section suivante revient à l'entraînement : une perte d'entraînement qui diminue ne suffit pas à montrer que les prédictions s'améliorent sur de nouveaux exemples.

Régularisation

Définition

La **régularisation** est une modification d'un algorithme d'apprentissage visant à **réduire son erreur de généralisation**.

Quelle sauvegarde déploieriez-vous?

L'erreur d'entraînement continue de diminuer. La courbe de validation justifie-t-elle de poursuivre l'entraînement?

In [8]:
```
from copy import deepcopy
from sklearn.metrics import root_mean_squared_error
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import PolynomialFeatures
from sklearn.linear_model import SGDRegressor
```

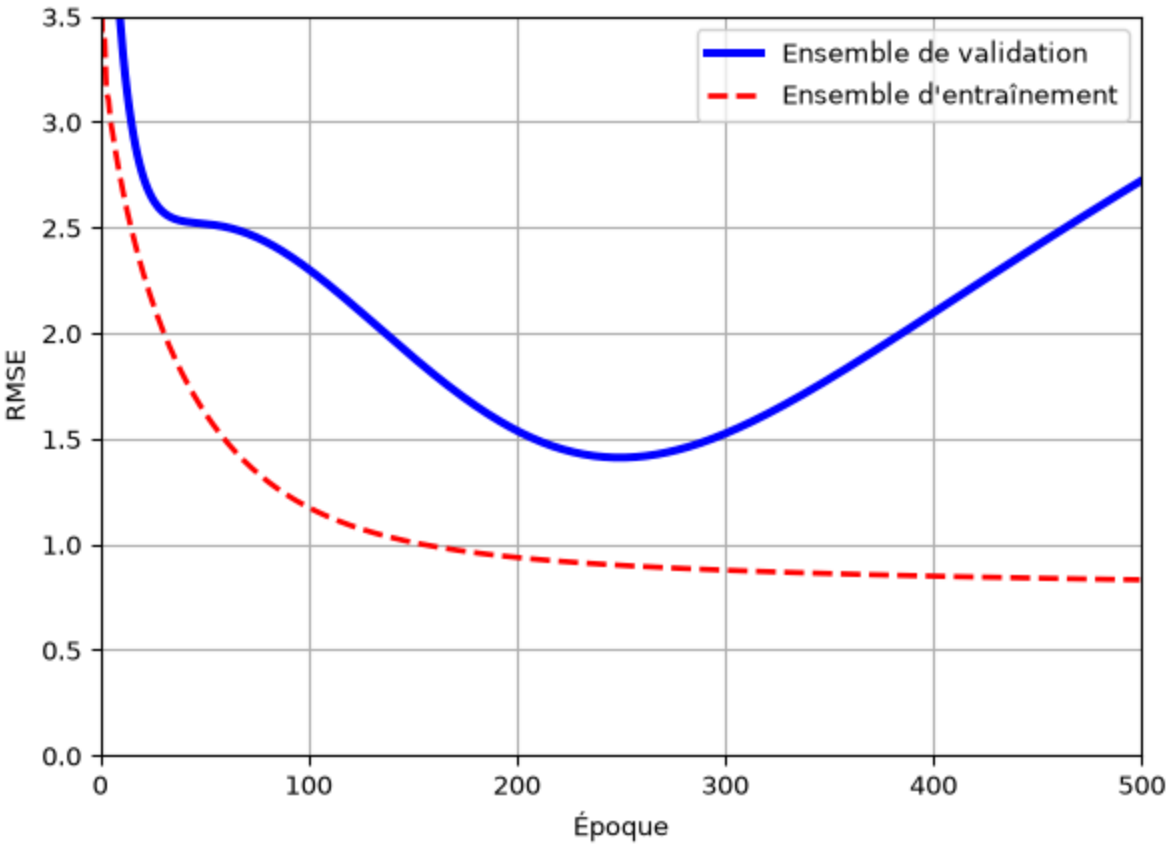
```
# Générer des données quadratiques bruitées et réserver des exemples de vali
np.random.seed(42)
m = 100
X = 6 * np.random.rand(m, 1) - 3
y = 0.5 * X ** 2 + X + 2 + np.random.randn(m, 1)
X_train, y_train = X[: m // 2], y[: m // 2, 0]
X_valid, y_valid = X[m // 2 :], y[m // 2 :, 0]

preprocessing = make_pipeline(PolynomialFeatures(degree=90, include_bias=Fal
                              StandardScaler())
X_train_prep = preprocessing.fit_transform(X_train)
X_valid_prep = preprocessing.transform(X_valid)
sgd_reg = SGDRegressor(penalty=None, eta0=0.002, random_state=42)
n_epochs = 500
best_valid_rmse = float('inf')
train_errors, val_errors = [], []  # Code complémentaire pour la figure ci-d

for epoch in range(n_epochs):
    sgd_reg.partial_fit(X_train_prep, y_train)
    y_valid_predict = sgd_reg.predict(X_valid_prep)
    val_error = root_mean_squared_error(y_valid, y_valid_predict)
    if val_error < best_valid_rmse:
        best_valid_rmse = val_error
        best_model = deepcopy(sgd_reg)

    # Code complémentaire : calculer et conserver l'erreur d'entraînement po
    y_train_predict = sgd_reg.predict(X_train_prep)
    train_error = root_mean_squared_error(y_train, y_train_predict)
    val_errors.append(val_error)
    train_errors.append(train_error)

# Code complémentaire : produire et sauvegarder la figure 4–20
best_epoch = np.argmin(val_errors)
plt.plot(val_errors, "b-", linewidth=3, label="Ensemble de validation")
plt.plot(train_errors, "r--", linewidth=2, label="Ensemble d'entraînement")
plt.legend(loc="upper right")
plt.xlabel("Époque")
plt.ylabel("RMSE")
plt.axis([0, n_epochs, 0, 3.5])
plt.grid()
plt.show()
```



Attribution : Géron (2022), 04_training_linear_models.ipynb.

Les choix de sortie et de perte définissaient ce que le modèle devait prédire. Cette figure introduit un deuxième critère de progrès : la performance sur des exemples qui ne servent pas aux mises à jour. La plus faible erreur de validation désigne un point de sauvegarde plus prometteur que la dernière époque, malgré la diminution continue de l'erreur d'entraînement.

Un **point de sauvegarde** (*checkpoint*) est une copie des paramètres du modèle à une étape donnée de l'entraînement. L'axe vertical utilise la **racine de l'erreur quadratique moyenne (RMSE)**, soit la racine carrée de la MSE introduite à la présentation 4; de faibles valeurs indiquent de plus petites erreurs de prédiction, dans les unités d'origine de la cible.

Le code exécute délibérément les 500 époques pour montrer les courbes complètes et conserve le meilleur modèle sans l'indiquer sur le graphique. Il illustre donc le choix d'un point de sauvegarde. Une véritable procédure d'**arrêt précoce** (*early stopping*) interrompt aussi les mises à jour lorsque son critère est satisfait. Les courbes de validation peuvent fluctuer; une période de patience évite de s'arrêter dès une petite détérioration. La courbe motive la règle d'arrêt présentée ensuite.

Pourquoi régulariser?

Une perte appropriée et des mises à jour efficaces peuvent quand même produire du **surapprentissage** (*overfitting*).

- La **perte d'entraînement** mesure l'ajustement aux exemples fournis.
- La **performance de validation** aide à choisir des modèles qui généralisent.
- Une régularisation plus forte peut aussi causer du sous-apprentissage (*underfitting*).

L'écart entre les courbes d'entraînement et de validation explique pourquoi réduire la perte d'entraînement n'est pas le seul objectif. **La régularisation influence l'apprentissage pour favoriser des solutions qui généralisent.** L'arrêt précoce contrôle la durée d'ajustement des paramètres; les pénalités modifient l'objectif; le dropout modifie les calculs d'entraînement. Leur utilité et leur intensité doivent être évaluées sur les données de validation; le jeu de test reste réservé à l'évaluation finale.

Arrêt précoce

Comment transformer la courbe de validation en règle d'arrêt?

Surveiller une mesure de validation. Arrêter après un nombre choisi d'époques sans amélioration significative, puis récupérer les meilleurs paramètres.

Geoffrey Hinton parle d'un *« beautiful free lunch »*, un avantage obtenu sans coût supplémentaire appréciable.

Arrêter et restaurer les meilleurs paramètres

Pour un modèle Keras compilé, avec des données d'entraînement et de validation préparées :

```
early_stopping = keras.callbacks.EarlyStopping(
    monitor="val_loss", patience=5, restore_best_weights=True)

model.fit(X_train, y_train, validation_data=(X_valid, y_valid),
          epochs=100, callbacks=[early_stopping])
```

Restaurer les meilleurs poids est un choix explicite : Keras ne le fait pas par défaut. La patience contrôle le nombre d'époques sans amélioration tolérées avant l'arrêt. On peut aussi fixer une amélioration minimale avec `min_delta`. Ce choix doit utiliser la validation, et non le test. Voir EarlyStopping dans Keras.

Ajouter une pénalité à la fonction objectif

Au-delà du moment d'arrêt, peut-on influencer les solutions privilégiées par l'entraînement?

$$J_{\text{reg}}(W, b) = J_{\text{data}}(W, b) + \Omega(W).$$

La perte des données correspond à la tâche de prédiction. La pénalité décourage certaines configurations des poids.

Le terme lié aux données peut être l'erreur quadratique moyenne, l'erreur absolue moyenne, la BCE ou l'entropie croisée catégorielle. Par exemple, la MAE moyenne $|\hat{y}_i - y_i|$ sur les exemples de régression. Une pénalité s'ajoute séparément et est minimisée avec ce terme. Dans cette présentation, les pénalités visent les poids, et non les biais, sauf indication contraire.

Comment mesurer la taille des poids?

Ces deux vecteurs de poids recevraient-ils la même pénalité?

Poids	Somme des valeurs absolues	Somme des carrés
$(4, 0)$	4	16
$(2, 2)$	4	8

L1 utilise $\|\mathbf{w}\|_1 = \sum_j |w_j|$; la pénalité L2 habituelle utilise $\|\mathbf{w}\|_2^2 = \sum_j w_j^2$.

Les deux vecteurs ont la même somme de valeurs absolues, mais répartir l'amplitude sur les deux composantes réduit la somme des carrés. Cette comparaison explique comment les pénalités mesurent différemment la taille des poids; elle ne prouve pas à elle seule que L1 produira un modèle ajusté parcimonieux. Le terme de perte des données influence aussi l'optimum.

La norme L1 est aussi appelée norme de Manhattan. La norme L2 ou euclidienne est la racine carrée de la somme des carrés; la pénalité habituelle de régularisation L2 utilise son carré, plutôt que la norme elle-même.

Une **norme** attribue une longueur non négative à un vecteur.

Pour $p \geq 1$, la **norme** ℓ_p d'un vecteur $\mathbf{z} = [z_1, z_2, \ldots, z_n]$ est définie par :

$$\|\mathbf{z}\|_p = \left(\sum_{i=1}^{n} |z_i|^p \right)^{1/p}$$

Lorsque p augmente, la norme ℓ_p accorde davantage d'importance aux grandes valeurs de z_i à cause de l'exponentiation.

Une **norme** est non négative et ne s'annule que pour le vecteur nul. Multiplier un vecteur par un scalaire c multiplie sa norme par $|c|$: $\|c\mathbf{z}\| = |c|\,\|\mathbf{z}\|$. L'**inégalité triangulaire**, $\|\mathbf{u}+\mathbf{v}\| \le \|\mathbf{u}\| + \|\mathbf{v}\|$, indique que la longueur d'une somme ne dépasse pas la somme des longueurs.

Régularisation ℓ_1 et ℓ_2

Soit $\mathbf{w}$ le vecteur de tous les poids. Les coefficients non négatifs λ_1 et λ_2 contrôlent les pénalités; zéro désactive le terme correspondant.

$$J_{\text{reg}} = J_{\text{data}}(W, b) + \lambda_1 \|\mathbf{w}\|_1 + \frac{\lambda_2}{2}\|\mathbf{w}\|_2^2.$$

Le terme L1 additionne les valeurs absolues des poids. La pénalité L2 habituelle additionne leurs carrés : elle utilise le carré de la norme euclidienne ou de Frobenius, plutôt que la norme elle-même. Le facteur un demi est une convention qui donne la dérivée $\lambda_2 W$, comme dans `SimpleMLP` plus loin. Les conventions de coefficients diffèrent selon les bibliothèques.

Réduction des coefficients et parcimonie

- **Régularisation ℓ_1** :
  - Favorise la **parcimonie** (*sparsity*); des solveurs appropriés peuvent fixer des coefficients exactement à zéro.
  - Peut permettre la **sélection d'attributs**, surtout dans les modèles linéaires.
- **Régularisation ℓ_2** :
  - Favorise des **poids petits et répartis** pour la stabilité.
  - Réduit collectivement les poids et conserve habituellement une solution dense.

Exemple avancé, en anglais : Régularisation avec attributs corrélés .

La **réduction des coefficients** (*shrinkage*) désigne la réduction de leur amplitude sous l'effet de la pénalité. Un **vecteur de coefficients parcimonieux** (*sparse coefficient vector*) contient de nombreux zéros exacts; un vecteur **dense** en contient peu ou aucun. La **sélection d'attributs** (*feature selection*) consiste à conserver un sous-ensemble des attributs d'entrée d'origine. Dans un modèle linéaire, un coefficient nul supprime le terme de cet attribut dans la prédiction. L'effet du sous-ensemble choisi sur la prédiction doit être évalué séparément. Des **attributs corrélés** varient ensemble; le chevauchement de leur information peut influencer les coefficients choisis et la répartition des poids.

Quels coefficients disparaissent vraiment?

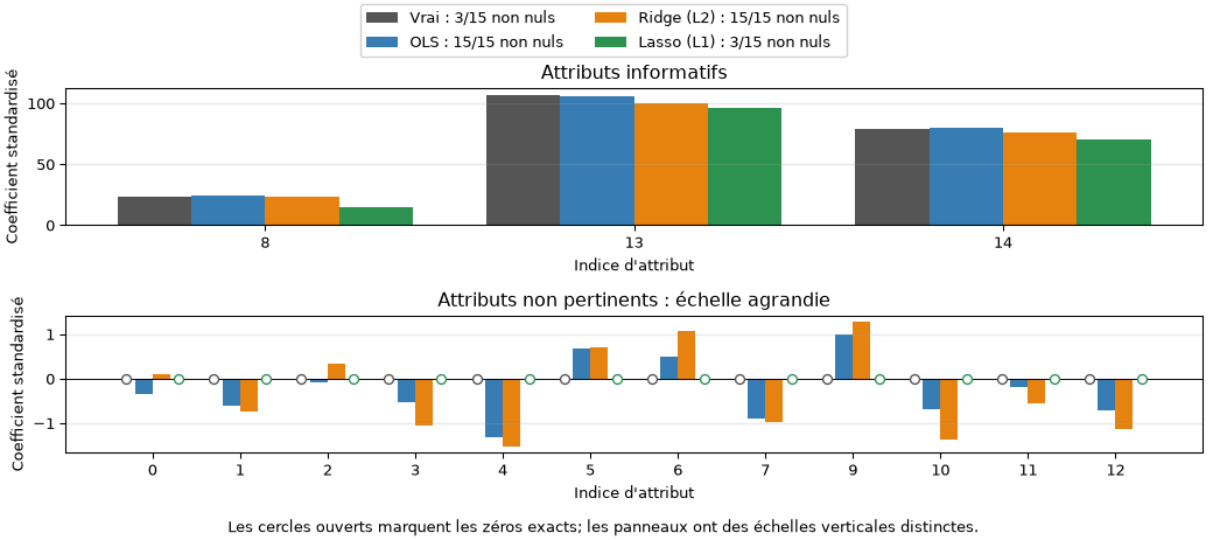
In [9]:
```
import numpy as np
import matplotlib.pyplot as plt
```

```python
from sklearn.datasets import make_regression
from sklearn.linear_model import LinearRegression, Ridge, Lasso
from sklearn.preprocessing import StandardScaler

X, y, true_coef = make_regression(n_samples=200, n_features=15, n_informativ
                                  noise=10.0, coef=True, random_state=42)
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# Exprimer les coefficients connus dans les mêmes coordonnées que les modèle
true_coef_scaled = true_coef * scaler.scale_
coefficient_models = {
    'OLS': LinearRegression().fit(X_scaled, y),
    'Ridge (L2)': Ridge(alpha=10.0).fit(X_scaled, y),
    'Lasso (L1)': Lasso(alpha=10.0).fit(X_scaled, y)
}

series = [('Vrai', true_coef_scaled)] + [
    (name, fitted.coef_) for name, fitted in coefficient_models.items()
]
colors = ['#555555', '#377eb8', '#e68613', '#319354']
groups = [
    (true_coef != 0, 'Attributs informatifs'),
    (true_coef == 0, 'Attributs non pertinents : échelle agrandie')
]
fig, axes = plt.subplots(2, 1, figsize=(11, 4.8))
for ax, (mask, title) in zip(axes, groups):
    feature_indices = np.flatnonzero(mask)
    positions = np.arange(len(feature_indices))
    for offset, ((name, values), color) in enumerate(zip(series, colors)):
        x_positions = positions + (offset-1.5)*0.2
        nonzero = np.count_nonzero(values)
        ax.bar(x_positions, values[mask], width=0.2, color=color,
               label=f'{name} : {nonzero}/15 non nuls')
        zeros = values[mask] == 0
        ax.scatter(x_positions[zeros], values[mask][zeros], s=35,
                   facecolors='white', edgecolors=color, zorder=4)
    ax.set(xticks=positions, xticklabels=feature_indices, xlabel="Indice d'a
           ylabel='Coefficient standardisé', title=title)
    ax.axhline(0, color='black', linewidth=0.7)
    ax.grid(axis='y', alpha=0.2)
handles, labels = axes[0].get_legend_handles_labels()
fig.legend(handles, labels, loc='upper center', ncol=2)
fig.text(0.5, 0.01, 'Les cercles ouverts marquent les zéros exacts; les panr
         ha='center')
fig.tight_layout(rect=(0, 0.035, 1, 0.91))
plt.show()
```



Les cercles ouverts marquent les zéros exacts; les panneaux ont des échelles verticales distinctes.

Régularisation : réduction des coefficients et parcimonie .

Cet exemple de régression linéaire isole l'effet de la pénalité. Quinze prédicteurs sont générés, mais seuls trois ont un vrai coefficient non nul. Les attributs informatifs et non pertinents utilisent des échelles verticales distinctes pour rendre visibles les petites estimations non nulles. Les cercles ouverts marquent les zéros exacts. Avec ces réglages fixes, OLS et Ridge conservent quinze coefficients non nuls; Lasso en conserve trois, soit 80 % de zéros exacts, et identifie les prédicteurs informatifs de ce jeu de données.

Les **moindres carrés ordinaires (OLS)** ajustent un modèle linéaire en minimisant la **somme des carrés des résidus (RSS)**. Un résidu est la cible observée moins sa prédiction; la RSS additionne les résidus au carré sur les exemples. C'est la fonction objectif des moindres carrés de la présentation 4, sous son nom statistique. **Ridge** ajoute une pénalité L2 au carré sur les coefficients; **Lasso** ajoute une pénalité L1. Voir les définitions des modèles linéaires de scikit-learn.

OLS sert de référence sans régularisation. Des valeurs numériques égales d'alpha n'impliquent pas des pénalités d'intensité égale. Ridge dans scikit-learn minimise la RSS plus alpha fois le carré de la norme L2, tandis que Lasso divise la RSS par $2N$ avant d'ajouter sa pénalité L1. Ces réglages servent une comparaison qualitative, et non une comparaison à intensité égale.

Les modèles utilisent des **attributs** (*features*) standardisés : chacun est centré selon sa moyenne d'entraînement puis divisé par son écart-type d'entraînement. Cette **standardisation** (*standardization*) explicite l'hypothèse d'échelle. Les vrais coefficients sont exprimés dans les mêmes coordonnées. Modifier les unités d'un attribut change le coefficient nécessaire pour préserver une prédiction, et donc sa pénalité. Les attributs générés ont déjà des échelles similaires, d'où une faible différence numérique ici. Pour une évaluation sur des données réservées, ajuster le standardiseur uniquement sur

l'entraînement. Le carnet explique la conversion des coefficients et affiche tous les décomptes.

Ajouter L2 dans Keras

```
import keras

l2 = 0.001
regularizer = keras.regularizers.L2(l2 / 2)
dense = keras.layers.Dense(50, kernel_regularizer=regularizer)
```

Pour une couche Dense, le **kernel** est sa matrice de poids. Appliquer la pénalité à chaque couche dont les poids doivent être pénalisés.

Keras `L2(c)` ajoute $c \sum w^2$; sa dérivée est donc $2cW$. Utiliser `c=l2/2` respecte la convention $\lambda/2$ de cette présentation et de `SimpleMLP`. Un coefficient numérique de pénalité ne prend son sens qu'avec la définition de la bibliothèque.
`kernel_regularizer` ne pénalise pas le biais; c'est une option distincte. Voir les régulariseurs de Keras.

Et si certaines activations étaient indisponibles?

Supprimer temporairement des activations cachées pourrait-il aider un modèle à généraliser?

- Le **dropout** met aléatoirement certaines activations à zéro pendant l'entraînement.
- **Objectif :** réduire le surapprentissage en décourageant la dépendance à la disponibilité permanente d'unités particulières.

Hinton et al. (2012)

Supposons qu'une prédiction dépende fortement d'une unité cachée. Lorsque le dropout met son activation à zéro pour un exemple d'entraînement, sa contribution devient indisponible. Les autres unités doivent fournir l'information utilisée pour cette prédiction. Répéter ce processus en supprimant différentes activations encourage des prédictions utiles sans dépendre excessivement de combinaisons particulières d'unités (Hinton et al. 2012).

L'objectif est une meilleure performance sur de nouveaux exemples. L'entraînement peut devenir plus difficile et sa perte peut augmenter; la performance de validation détermine si le dropout améliore la généralisation. Un dropout excessif peut causer du sous-apprentissage.

Les pénalités sur les poids modifient l'objectif en ajoutant un terme qui dépend des poids. Le dropout modifie le calcul d'entraînement. Les mêmes paramètres sont partagés entre ces calculs, et différentes activations sont choisies aléatoirement pour

être supprimées au fil de l'entraînement. Les unités et leurs poids restent dans le modèle; les valeurs des activations sont temporairement modifiées.

Pourquoi redimensionner les activations conservées?

Une activation vaut 4 avant le dropout et est supprimée la moitié du temps. Quelle est sa valeur moyenne après le dropout?

Résultat	Sans mise à l'échelle	Avec mise à l'échelle
Supprimée (la moitié du temps)	0	0
Conservée (la moitié du temps)	4	8
Moyenne	**2**	**4**

Pour un taux de dropout p, diviser chaque activation conservée par $1 - p$.

Le **taux de dropout** p est la probabilité de mettre une activation à zéro pendant l'entraînement, avec $0 \leq p < 1$. L'activation est conservée avec probabilité $1 - p$. Les deux résultats du tableau sont équiprobables, puisque $p = 0.5$.

Sans mise à l'échelle, la moyenne est $(0 + 4)/2 = 2$. Diviser les activations conservées par $1 - p = 0.5$ les double et donne une moyenne de $(0 + 8)/2 = 4$. Cela compense les activations supprimées. Plus généralement, une activation d'origine a devient zéro si elle est supprimée et $a/(1 - p)$ si elle est conservée.

Cette moyenne décrit de nombreuses répétitions avec la même activation d'origine; un seul calcul produit ici soit 0, soit 8. La mise à l'échelle garde une amplitude moyenne comparable à l'utilisation habituelle, tandis que chaque calcul comporte encore des activations manquantes. Cette variation fournit l'effet de régularisation. Elle ne garantit pas que la prédiction finale du réseau soit préservée en moyenne, puisque les couches suivantes peuvent être non linéaires.

Avec les réglages habituels de Keras, les choix aléatoires se font séparément pour chaque exemple et chaque activation. Une unité peut donc être supprimée pour certains exemples et conservée pour d'autres dans le même lot. Pour un exemple où une activation est supprimée, aucun gradient ne la traverse; d'autres exemples peuvent toujours contribuer aux mises à jour des paramètres de l'unité.

Entraînement et inférence

Faut-il encore supprimer des activations lorsque le modèle entraîné fait des prédictions?

Mode	Supprimer des activations?	Redimensionner les activations conservées?
Entraînement	Oui, au taux p	Oui, par $1/(1-p)$
Inférence	Non	Non

Pendant l'inférence habituelle, toutes les unités sont disponibles et le dropout laisse les activations inchangées. Les activations conservées ayant été redimensionnées pendant l'entraînement, aucune mise à l'échelle supplémentaire liée au dropout n'est nécessaire à l'inférence.

Keras gère automatiquement cette distinction : le dropout est actif pour l'entraînement dans `model.fit` et inactif pour la validation, `model.evaluate` et `model.predict`. La validation mesure donc le modèle dans ses conditions habituelles de prédiction. Voir Dropout dans Keras.

Dropout dans le modèle Fashion-MNIST

```
import keras
from keras.models import Sequential
from keras.layers import InputLayer, Dropout, Flatten, Dense

model = keras.Sequential([
    InputLayer(shape=[28, 28]),
    Flatten(),
    Dropout(rate=0.2),
    Dense(300, activation="relu"),
    Dropout(rate=0.2),
    Dense(100, activation="relu"),
    Dropout(rate=0.2),
    Dense(10, activation="softmax")
])
```

Ajout de couches `Dropout` au modèle Fashion-MNIST de la présentation 11. Un taux de 0.2 supprime chaque activation avec une probabilité de 20 % pendant l'entraînement.

Chaque couche `Dropout` agit sur les activations fournies par la couche précédente. Après `Flatten`, il s'agit des valeurs des pixels d'entrée; après une couche `Dense`, des activations des unités cachées. Une couche `Dropout` n'ajoute aucun poids entraînable. La rétropropagation calcule toujours les gradients des couches Dense voisines et l'optimiseur met à jour leurs paramètres comme précédemment.

Le taux est une probabilité par activation; il n'est pas nécessaire de supprimer exactement 20 % des activations pour chaque exemple. Avec `rate=0.2`, chaque activation conservée est divisée par 0.8, donc multipliée par 1.25, pendant l'entraînement. Le taux peut varier selon la couche.

Cet exemple montre où insérer le dropout dans une architecture familière. Pour savoir s'il améliore les prédictions, comparer la performance de validation à celle d'un modèle autrement comparable sans dropout. Choisir les taux à partir de la validation; un dropout trop fort peut compliquer l'apprentissage de régularités utiles.

Poursuite de l'apprentissage et rétention

Inférence et poursuite de l'apprentissage

Le modèle fonctionne bien. Peut-il continuer à apprendre de nouveaux exemples sans perdre ses capacités antérieures?

- **Inférence :** calculer des prédictions avec les paramètres actuels.
- **Poursuite de l'apprentissage :** mettre à jour les paramètres par un processus d'entraînement explicite.
- Évaluer les mises à jour sur les **capacités antérieures** autant que sur les nouvelles données.

Un modèle ne modifie habituellement pas ses poids simplement parce qu'il reçoit une nouvelle demande de prédiction. L'apprentissage exige une rétroaction, un objectif et une procédure de mise à jour. Une chaîne d'entraînement peut produire périodiquement une nouvelle version du modèle ou le mettre à jour continuellement.

L'**apprentissage en ligne** (*online learning*) met à jour un modèle progressivement à mesure que de nouvelles observations arrivent, au lieu de s'appuyer uniquement sur un jeu fixe et une phase distincte de réentraînement. L'**ajustement fin** (*fine-tuning*) est la poursuite de l'entraînement d'un modèle déjà entraîné. L'**apprentissage continu** (*continual learning*) étudie l'apprentissage sur des données ou des tâches successives tout en conservant les capacités antérieures. Ces termes décrivent des processus d'apprentissage; l'inférence habituelle calcule les sorties sans effectuer ces mises à jour.

Des réseaux en production peuvent apprendre en ligne; des systèmes de recommandation en temps réel comme Monolith en sont des exemples. La distinction porte sur l'inférence et le processus délibéré de mise à jour, et non sur une interdiction générale de l'entraînement en ligne. Voir la discussion de Google sur l'entraînement statique et dynamique.

Apprendre B préservera-t-il la capacité A?

Phase	Données d'entraînement	Évaluation ensuite
A	Chiffres MNIST 0–4	Les deux groupes
B	Chiffres MNIST 5–9	Les deux groupes

Conserver les dix mêmes classes de sortie et les étiquettes d'origine pendant toute l'expérience.

Après la phase B, que prévoyez-vous pour l'exactitude sur les chiffres 0–4?

Le modèle s'entraîne d'abord sur les chiffres 0–4, puis poursuit l'entraînement sur les chiffres 5–9. La dimension de sortie et le sens de chaque étiquette restent fixes. La seconde phase vérifie donc si l'apprentissage de nouvelles classes préserve les prédictions antérieures sans fournir d'anciens exemples supplémentaires. Cela diffère de l'inférence habituelle, qui laisse les paramètres inchangés.

MNIST contient des images de chiffres manuscrits de 0 à 9, en niveaux de gris et de 28 par 28 pixels. Il diffère de Fashion-MNIST, le jeu d'images de vêtements utilisé plus tôt. Une configuration d'**apprentissage incrémental par classes** (*class-incremental learning*) introduit des classes par phases successives et évalue la reconnaissance de toutes les classes rencontrées jusque-là; après la phase B, il s'agit ici des dix chiffres.

Cette configuration est incrémentale par classes : les dix classes sont disponibles pour chaque prédiction. Restreindre les prédictions au groupe de classes connu de la tâche répondrait à une autre question, plus facile. Voir van de Ven et Tolias (2019).

Que sont devenues les classes antérieures?

Exactitude au test dans l'exécution MNIST consignée :

Point de sauvegarde	Chiffres 0–4 (A)	Chiffres 5–9 (B)
Après A	97.0 %	0.0 %
Après B seulement	2.3 %	93.8 %

Quels exemples étaient absents de la phase B? Comment réintroduire une partie de cette information?

Oubli catastrophique (*catastrophic forgetting*) : poursuivre l'entraînement peut réduire fortement la performance sur des tâches antérieures.

Ces exactitudes au test ont été mesurées en fin de phase dans l'exécution consignée du carnet complémentaire; ce ne sont pas les exactitudes de validation tracées à la diapositive suivante. Chaque évaluation considère les dix classes de sortie. Les valeurs exactes peuvent varier selon le moteur de calcul et le matériel, mais cette exécution illustre une perte prononcée d'exactitude sur les anciennes classes malgré l'apprentissage réussi des nouvelles.

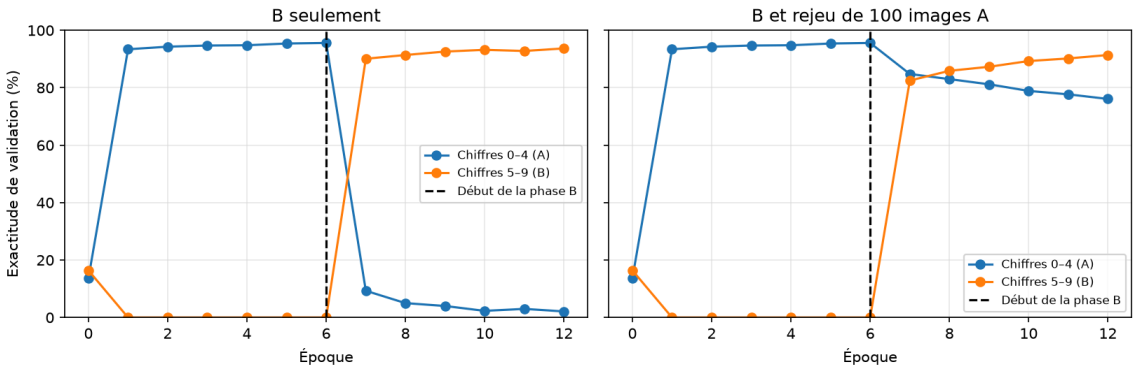
Le deuxième objectif d'entraînement ne contient aucun exemple exigeant que les prédictions antérieures restent correctes. Ses mises à jour peuvent perturber les représentations partagées et favoriser les classes récentes. Les images et les étiquettes

du test d'origine ne changent pas. Une baisse ne prouve pas que toutes les anciennes représentations utiles ont été effacées.

L'absence d'anciens exemples suggère une intervention directe : conserver une petite mémoire et mélanger des exemples antérieurs aux mises à jour suivantes. Cette proposition est testée ensuite avec les mêmes paramètres appris au départ et le même nombre de mises à jour pour les deux branches de la phase B.

Une petite mémoire pourrait-elle aider?

Que changerait l'inclusion d'anciens exemples dans certaines mises à jour de la phase B?



Oubli catastrophique sur MNIST : reproduire l'expérience et examiner les résultats de test en fin de phase.

Les deux panneaux partagent le même historique de phase A et commencent la phase B avec des paramètres appris identiques. Les deux branches de phase B ont la même taille de lot et le même nombre de mises à jour. La seconde utilise la moitié de chaque lot pour réutiliser des exemples issus d'une mémoire équilibrée de 100 anciennes images d'entraînement; cela modifie le mélange des données dans ce budget fixe.

Une **mémoire équilibrée** conserve le même nombre d'exemples de chaque ancienne classe : ici, 20 images de chacune des cinq classes A. La **rétention** est le maintien de la performance sur les anciennes données après un entraînement ultérieur.

Cette réutilisation d'anciens exemples conservés en mémoire constitue le **rejeu d'exemples** (*replay*). Dans cette exécution, elle améliore nettement la rétention tout en permettant l'apprentissage des nouvelles classes; elle ne préserve pas parfaitement l'exactitude antérieure.

La figure utilise l'exactitude de validation pour suivre les deux capacités. Le carnet consigne des mesures de fin de phase prédéfinies sur le jeu de test officiel de MNIST et rapporte séparément la baisse d'exactitude sur A. La seule performance sur la nouvelle tâche masquerait le problème de rétention.

Le rejeu d'exemples réintroduit un objectif sur les anciennes données. La régularisation L2 habituelle centrée en zéro décourage les grands poids; elle ne préserve pas explicitement les prédictions antérieures. Pour approfondir, la consolidation élastique des poids (EWC) pénalise les écarts par rapport aux paramètres appris précédemment, avec des pénalités plus fortes pour les paramètres jugés importants aux tâches antérieures. L'oubli catastrophique concerne l'ajustement fin périodique par lots autant que les mises à jour en ligne.

Épilogue

Résumé

- **Optimisation :** un gradient local correct ne garantit pas un entraînement réussi.
- **Propagation des gradients :** activation, initialisation, écrêtage et taille des mises à jour répondent à différentes difficultés.
- **Sorties et pertes :** choisir ensemble la représentation de sortie et l'objectif; distinguer logits, probabilités et étiquettes de classe.
- **Généralisation :** L1/L2, dropout et arrêt précoce peuvent aider; évaluer leur intensité avec la validation.
- **Rétention :** poursuivre l'entraînement peut causer de l'oubli; évaluer les acquis et envisager le rejeu d'exemples.
- **Implémentation :** `SimpleMLP` conserve la structure de rétropropagation tout en ajoutant des choix d'entraînement.

Prochaine présentation

Pour les images, une architecture pourrait-elle exploiter la structure spatiale plutôt que traiter toutes les connexions d'entrée de la même manière?

- Les réseaux de neurones convolutifs répondent à cette question d'architecture.

Références

Géron, Aurélien. 2022. *Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow*. 3e éd. O'Reilly Media, Inc.

Glorot, Xavier, et Yoshua Bengio. 2010. « Understanding the difficulty of training deep feedforward neural networks ». In *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*, édité par Yee Whye Teh et Mike Titterington, vol. 9. Proceedings of Machine Learning Research. PMLR. https://proceedings.mlr.press/v9/glorot10a.html.

Hinton, Geoffrey E., Nitish Srivastava, Alex Krizhevsky, Ilya Sutskever, et Ruslan Salakhutdinov. 2012. « Improving neural networks by preventing co-adaptation of feature detectors ». *CoRR* abs/1207.0580. http://arxiv.org/abs/1207.0580.

Krizhevsky, Alex, Ilya Sutskever, et Geoffrey E Hinton. 2012. « ImageNet Classification with Deep Convolutional Neural Networks ». In *Advances in Neural Information Processing Systems*, édité par F. Pereira, C. J. Burges, L. Bottou, et K. Q. Weinberger, vol. 25. Curran Associates, Inc. https://proceedings.neurips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a Paper.pdf.

LeCun, Yann, Yoshua Bengio, et Geoffrey Hinton. 2015. « Deep learning ». *Nature* 521 (7553): 436-44. https://doi.org/10.1038/nature14539.

Rumelhart, David E., Geoffrey E. Hinton, et Ronald J. Williams. 1986. « Learning representations by back-propagating errors ». *Nature* 323 (6088): 533-36. https://doi.org/10.1038/323533a0.

Russell, Stuart, et Peter Norvig. 2020. *Artificial Intelligence: A Modern Approach*. 4e éd. Pearson. http://aima.cs.berkeley.edu/.

Annexe : étendre l'implémentation

De SimplerMLP à SimpleMLP

Quels choix exigent de modifier le code et où interviennent-ils dans les calculs?

Composante	**`SimplerMLP` (présentation 13)**	**`SimpleMLP`**
Activation cachée	Sigmoïde	Sigmoïde ou ReLU
Initialisation	Glorot	He pour ReLU; Glorot pour sigmoïde
Sortie	Probabilité sigmoïde	Probabilité sigmoïde
Taux d'apprentissage	Constant	Constant ou décroissance exponentielle
Perte	BCE moyenne	BCE moyenne et L2 facultative
Dropout	Aucun	Facultatif; même taux pour toutes les couches cachées
Ordre des exemples	Mélange à chaque époque	Mélange facultatif, activé par défaut
Valeurs conservées	Activations et préactivations	Aussi les masques de dropout redimensionnés

Composante	`SimplerMLP` (présentation 13)	`SimpleMLP`
API de prédiction et d'entraînement	Mêmes méthodes	Mêmes méthodes

La nouvelle classe étend l'implémentation précédente tout en conservant sa structure de calcul. Les deux sont des classifieurs binaires à sortie sigmoïde unique. Changer l'activation cachée exige une dérivée locale correspondante et une initialisation appropriée, mais la règle de dérivation en chaîne et la boucle arrière restent les mêmes.

Chaque ajout répond à une difficulté abordée plus tôt : les fonctions auxiliaires d'activation choisissent les pentes locales, l'initialisation contrôle l'échelle de départ des poids, L2 ajoute une pénalité, le dropout modifie le calcul d'entraînement et un calendrier fait évoluer la taille des mises à jour selon les époques. Les activations et préactivations conservées, l'orientation des matrices et la collecte des gradients restent cohérentes avec la présentation 13. Le dropout ajoute des masques redimensionnés conservés en mémoire et un facteur correspondant au passage arrière.

Cette classe implémente une sélection des choix de la présentation. Elle conserve la BCE binaire et n'implémente pas softmax multiclasse, l'arrêt précoce ou l'écrêtage des gradients. Les exemples Keras et les carnets illustrent ces autres outils. Ces portées distinctes gardent l'implémentation NumPy lisible tout en reliant les concepts au code.

Les réglages `hidden_activation="sigmoid"`, `l2=0.0`, `lr_decay=None` et `dropout_rate=0.0` redonnent les calculs de `SimplerMLP`. Avec la même graine et `shuffle=True` par défaut, les deux classes initialisent et mélangent les données de manière identique. `SimpleMLP` ajoute l'option `shuffle` à `train` : `shuffle=False` conserve l'ordre fourni des exemples d'une époque à l'autre. Cela est utile si l'entraînement dépend de cet ordre, comme expliqué dans la présentation 13; cela ne transforme pas à soi seul ce classifieur à propagation avant en modèle de séquences. La définition complète et des extraits ciblés suivent et restent disponibles pour l'exécution autonome du carnet.

SimpleMLP

In [10]:
```python
import numpy as np

def sigmoid(z):
    return 1.0 / (1.0 + np.exp(-z))

def sigmoid_prime(z):
    a = sigmoid(z)
    return a * (1.0 - a)

def bce_loss(y_true, y_prob, eps=1e-9):
    """Entropie croisée binaire moyennée sur les exemples."""
```

```
    p = np.clip(y_prob, eps, 1 - eps)
    return -np.mean(y_true * np.log(p) + (1 - y_true) * np.log(1 - p))

def xavier_init(rng, fan_in, fan_out):
    std = np.sqrt(2.0 / (fan_in + fan_out))
    return rng.normal(0.0, std, size=(fan_in, fan_out))

def relu(z):
    return np.maximum(0.0, z)

def relu_prime(z):
    return (z > 0).astype(float)

def he_init(rng, fan_in, fan_out):
    std = np.sqrt(2.0 / fan_in)
    return rng.normal(0.0, std, size=(fan_in, fan_out))

class SimpleMLP:
    """MLP binaire avec choix d'activation cachée, L2, dropout et décroissar

    def __init__(self, layer_sizes, lr=0.1, seed=None, l2=0.0,
                 hidden_activation="relu", lr_decay=None, dropout_rate=0.0):
        self.sizes = list(layer_sizes)
        self.lr = float(lr)
        self.base_lr = float(lr)
        self.l2 = float(l2)
        self.hidden_activation = hidden_activation
        self.lr_decay = lr_decay
        self.dropout_rate = float(dropout_rate)
        self.rng = np.random.default_rng(seed)

        self.W = []
        L = len(self.sizes) - 1
        for l, (din, dout) in enumerate(zip(self.sizes[:-1], self.sizes[1:])
            if l < L and self.hidden_activation == "relu":
                Wk = he_init(self.rng, din, dout)
            else:
                Wk = xavier_init(self.rng, din, dout)
            self.W.append(Wk)
        self.b = [np.zeros(dout) for dout in self.sizes[1:]]

    def _act(self, z, last=False):
        if last:
            return sigmoid(z)
        return relu(z) if self.hidden_activation == "relu" else sigmoid(z)

    def _act_prime(self, z, last=False):
        if last:
            return sigmoid_prime(z)
        return relu_prime(z) if self.hidden_activation == "relu" else sigmoi

    def forward(self, X):
        a = X
        L = len(self.W)
        for l, (W, b) in enumerate(zip(self.W, self.b), start=1):
            a = self._act(a @ W + b, last=(l == L))
```

```
        return a.ravel()

    def predict_proba(self, X):
        return self.forward(X)

    def predict(self, X, threshold=0.5):
        return (self.predict_proba(X) >= threshold).astype(int)

    def loss(self, X, y):
        """Rapporter la BCE moyenne et L2, sans dropout."""
        p = self.predict_proba(X)
        base = bce_loss(y, p)
        if self.l2 > 0:
            base += 0.5 * self.l2 * sum((W ** 2).sum() for W in self.W)
        return base

    def _forward_full(self, X):
        a = X
        activations = [a]
        zs = []
        dropout_masks = []
        L = len(self.W)
        for l, (W, b) in enumerate(zip(self.W, self.b), start=1):
            z = a @ W + b
            a = self._act(z, last=(l == L))

            # Masque identité pour la sortie et lorsque le dropout est désac
            mask = np.ones_like(a)
            if l < L and self.dropout_rate > 0:
                keep_prob = 1.0 - self.dropout_rate
                mask = (self.rng.random(a.shape) >= self.dropout_rate) / kee
                a = a * mask

            zs.append(z)
            activations.append(a)
            dropout_masks.append(mask)
        return activations, zs, dropout_masks

    def train(self, X, y, epochs=30, batch_size=None, verbose=True, shuffle=
        """X : (N, d), y : (N,); batch_size=None utilise toutes les données.
        N = X.shape[0]
        idx = np.arange(N)
        B = N if batch_size is None else int(batch_size)

        for ep in range(1, epochs + 1):
            if shuffle:
                self.rng.shuffle(idx)
            if self.lr_decay is not None:
                self.lr = self.base_lr * self.lr_decay ** (ep - 1)

            base_loss = self.loss(X, y)

            for start in range(0, N, B):
                sl = idx[start:start + B]
                Xb = X[sl]
                yb = y[sl].reshape(-1, 1)
```

```
                Bsz = Xb.shape[0]

                activations, zs, dropout_masks = self._forward_full(Xb)
                A_L = activations[-1]

                # Chaque ligne est la sensibilité aux préactivations pour un
                delta = A_L - yb
                grads_W = [None] * len(self.W)
                grads_b = [None] * len(self.b)

                # Moyenner une seule fois les gradients des paramètres sur l
                grads_W[-1] = activations[-2].T @ delta / Bsz
                grads_b[-1] = delta.mean(axis=0)

                for k in range(len(self.W) - 2, -1, -1):
                    z = zs[k]
                    d_act = self._act_prime(z, last=False)
                    delta = delta @ self.W[k + 1].T
                    delta = delta * dropout_masks[k]
                    delta = delta * d_act
                    grads_W[k] = activations[k].T @ delta / Bsz
                    grads_b[k] = delta.mean(axis=0)

                if self.l2 > 0:
                    for k in range(len(self.W)):
                        grads_W[k] += self.l2 * self.W[k]

                # Tous les gradients utilisent les poids du même passage ava
                for k in range(len(self.W)):
                    self.W[k] -= self.lr * grads_W[k]
                    self.b[k] -= self.lr * grads_b[k]

            new_loss = self.loss(X, y)
            if verbose:
                print(f"Époque {ep:3d} | perte {base_loss:.5f} -> {new_loss:
```

Choisir les activations cachées

Si l'activation du passage avant change, quelle dérivée locale le passage arrière doit-il utiliser?

```
    def _act(self, z, last=False):
        if last:
            return sigmoid(z)
        return relu(z) if self.hidden_activation == "relu" else
sigmoid(z)

    def _act_prime(self, z, last=False):
        if last:
            return sigmoid_prime(z)
        return relu_prime(z) if self.hidden_activation == "relu"
else sigmoid_prime(z)
```

La sortie reste sigmoïde pour la classification binaire. ReLU n'est proposée que pour les unités cachées. La présentation 13 appelait directement `sigmoid` et `sigmoid_prime`. Ici, `_act` et `_act_prime` choisissent l'activation et sa dérivée, tandis que `last` indique la couche de sortie. Les passages avant et avant avec valeurs conservées appellent maintenant `_act` ; la boucle arrière appelle `_act_prime`. La multiplication par `W_next.T` et la moyenne sur les exemples restent les mêmes.

L2 dans l'objectif et le gradient

$$J_{\text{reg}} = J_{\text{BCE}} + \frac{\lambda}{2} \sum_{l=1}^{L} \|W^{(l)}\|_F^2.$$

```
base += 0.5 * self.l2 * sum((W ** 2).sum() for W in self.W)

# Après le calcul des gradients moyens de la perte des données :
grads_W[k] += self.l2 * self.W[k]
```

Le coefficient `l2` est λ. La perte des données est moyennée sur les exemples; la pénalité s'ajoute séparément, sans autre division par la taille du jeu ou du mini-lot. Sa dérivée est donc λW dans chaque lot. Cela assure la cohérence entre le terme L2 de la perte rapportée et sa contribution aux mises à jour. Les biais ne sont pas pénalisés.

Le carré de la norme de Frobenius est simplement la somme des carrés des entrées d'une matrice de poids. Ce code implémente la pénalité L2 au carré introduite plus tôt. L2 décourage les grands poids; elle ne change pas les dérivées locales d'activation et ne répare pas directement la propagation des gradients.

Dropout aux passages avant et arrière

Quelle dérivée locale supplémentaire le dropout introduit-il?

Pendant le passage avant d'entraînement, pour une couche cachée :

```
keep_prob = 1.0 - self.dropout_rate
mask = (self.rng.random(a.shape) >= self.dropout_rate) / keep_prob
a = a * mask
```

Pendant le passage arrière, réutiliser le masque redimensionné conservé :

```
delta = delta * dropout_masks[k]
```

Activer avec `dropout_rate=0.2` ; la valeur par défaut zéro désactive le dropout.

`SimpleMLP` utilise un même taux pour **toutes les couches cachées**. Keras permet de placer des couches `Dropout` individuellement et de choisir leurs taux séparément.

Pour un taux $0 \leq p < 1$, chaque entrée du masque vaut zéro avec probabilité p, et $1/(1-p)$ sinon. Sa forme correspond au tableau d'activations du lot; les choix se font donc séparément pour chaque exemple et unité cachée. Le masque est échantillonné

une fois au passage avant d'entraînement et conservé pour son passage arrière. Un nouveau masque est échantillonné au passage avant d'entraînement suivant.

Pour un masque échantillonné fixé, $\tilde{a} = ma$ possède une dérivée locale m par rapport à a. Le passage arrière multiplie donc par le même masque redimensionné. Une activation supprimée bloque le gradient de ce chemin; une activation conservée transmet aussi le facteur de mise à l'échelle. La dérivée d'activation est évaluée à la préactivation `zs[k]` conservée avant le dropout. En particulier, il ne faut pas calculer la dérivée sigmoïde à partir d'une activation déjà masquée et redimensionnée.

La liste `activations` conserve les valeurs réellement transmises à la couche suivante, y compris l'effet du dropout. Les gradients des paramètres utilisent ces mêmes valeurs. La sortie n'est pas supprimée; son signal d'erreur sigmoïde/BCE reste donc `A_L - yb`.

Cette implémentation applique le même taux à chaque couche cachée. Elle n'applique pas de dropout aux entrées brutes ni à la sortie. Dans Keras, le dropout est configuré par des couches distinctes placées aux positions choisies, avec des taux indépendants; voir Dropout dans Keras.

Seule `_forward_full`, utilisée pour l'entraînement, applique le dropout. La méthode publique `forward`, les méthodes de prédiction et la perte `loss` rapportée utilisent le réseau complet, sans dropout. La perte affichée est donc une évaluation déterministe aux paramètres courants, tandis que les gradients de perte de chaque lot proviennent du calcul avec son masque échantillonné. La graine du constructeur contrôle l'initialisation, le mélange et les masques. Avec `dropout_rate=0.0`, aucun nombre aléatoire n'est tiré pour les masques, ce qui préserve le comportement reproductible de l'implémentation antérieure.

Même API, modèle étendu

In [11]:
```
from sklearn.datasets import make_circles
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import accuracy_score

X, y = make_circles(n_samples=200, factor=0.5, noise=0.08, random_state=1)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=0, stratify=y)

scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

model = SimpleMLP([2, 4, 4, 1], lr=0.3, seed=42,
                  hidden_activation="relu", l2=0.001, lr_decay=0.995)
model.train(X_train, y_train, epochs=500, batch_size=32, verbose=False)
```

```
print("Exactitude entraînement :", accuracy_score(y_train, model.predict(X_t
print(" Exactitude test :", accuracy_score(y_test, model.predict(X_test)))
```

```
Exactitude entraînement : 1.0
 Exactitude test : 1.0
```

Les données, la séparation, le prétraitement et l'architecture sont les mêmes que dans l'exemple `SimplerMLP`. Cet exemple illustre les options d'activation, de pénalité et de taux d'apprentissage; le dropout reste désactivé à sa valeur par défaut zéro. Puisque l'activation, la durée d'entraînement, la pénalité et le calendrier diffèrent, ces exécutions illustrent des démarches plutôt qu'une comparaison contrôlée établissant qu'un réglage est toujours meilleur. La graine du constructeur contrôle les poids, le mélange et les masques de dropout lorsqu'ils sont activés. Tous les gradients sont encore collectés avant les mises à jour.

Après l'entraînement et l'évaluation, une autre question se pose : qu'arrive-t-il aux capacités existantes si les paramètres du modèle sont ajustés avec de nouvelles données?

Calculer softmax de manière stable

Soustraire le plus grand logit préserve les probabilités et évite d'exponentier de grandes valeurs positives.

In [12]:
```
import numpy as np

logits = np.array([1000.0, 1001.0, 999.0])
exp_scores = np.exp(logits-logits.max())
probabilities = exp_scores/exp_scores.sum()
print('Probabilités :', probabilities.round(4))
print('Somme :', probabilities.sum())
```

```
Probabilités : [0.2447 0.6652 0.09  ]
Somme : 0.9999999999999999
```

Marcel **Turcotte**

Marcel.Turcotte@uOttawa.ca

École de génie électrique et d'**informatique** (GÉ**I**)

Université d'Ottawa